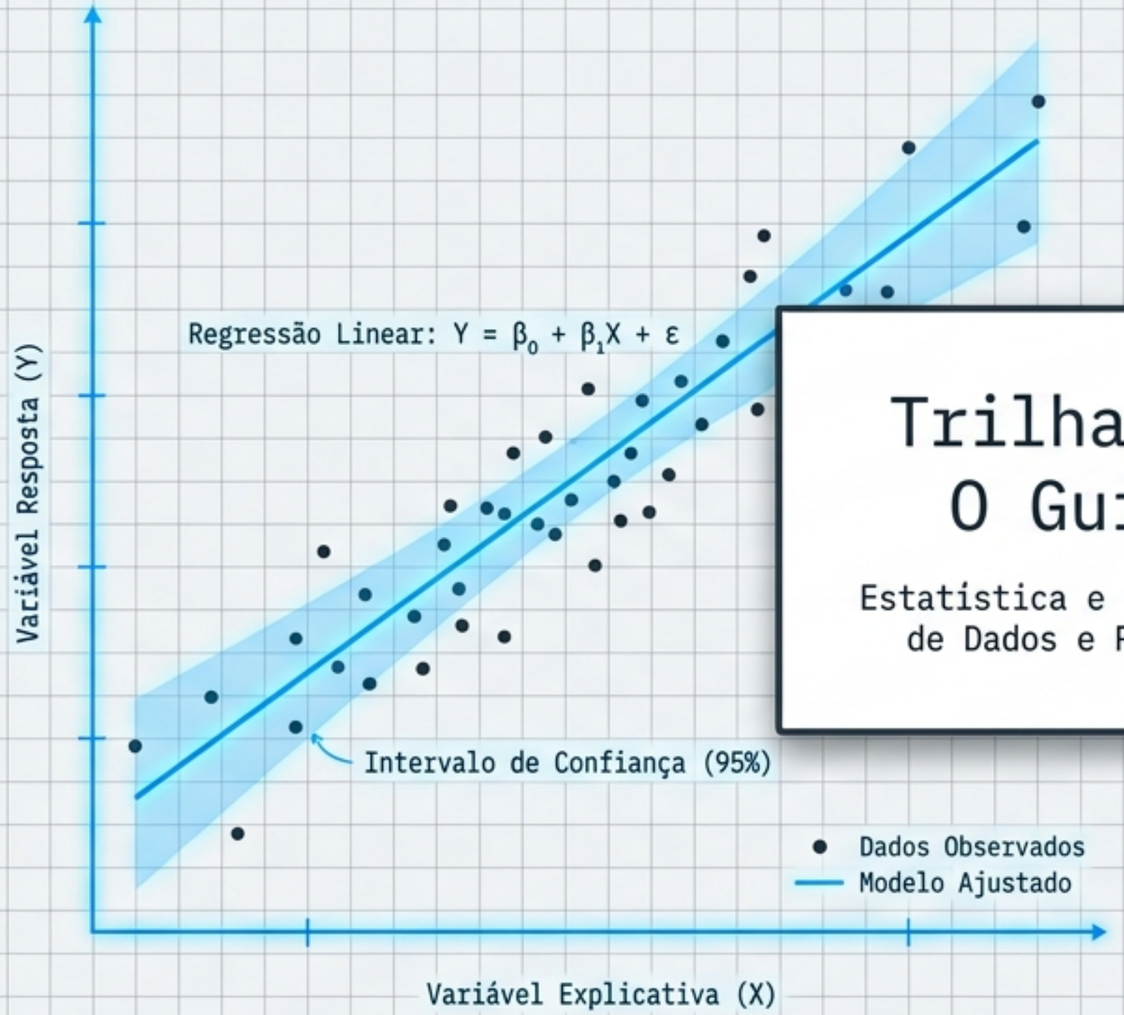
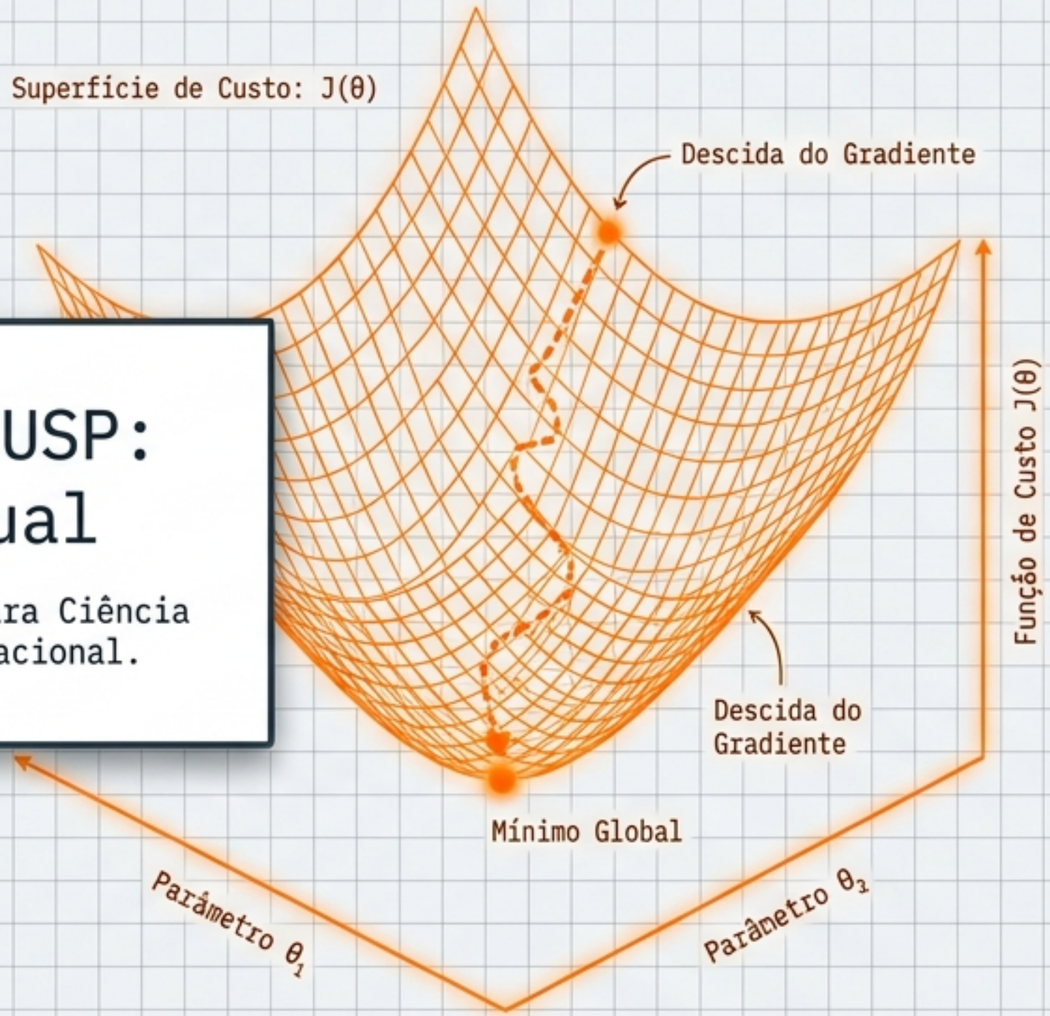
Trilha CDPO USP: O Guia Visual

Estatistica e Otimização para Ciência de Dados e Pesquisa Operacional.





// 5 aulas essenciais. conceitos, fórmulas e diagramas para iniciantes.

Gemini Notebook

O mapa de aprendizado da ciência de dados

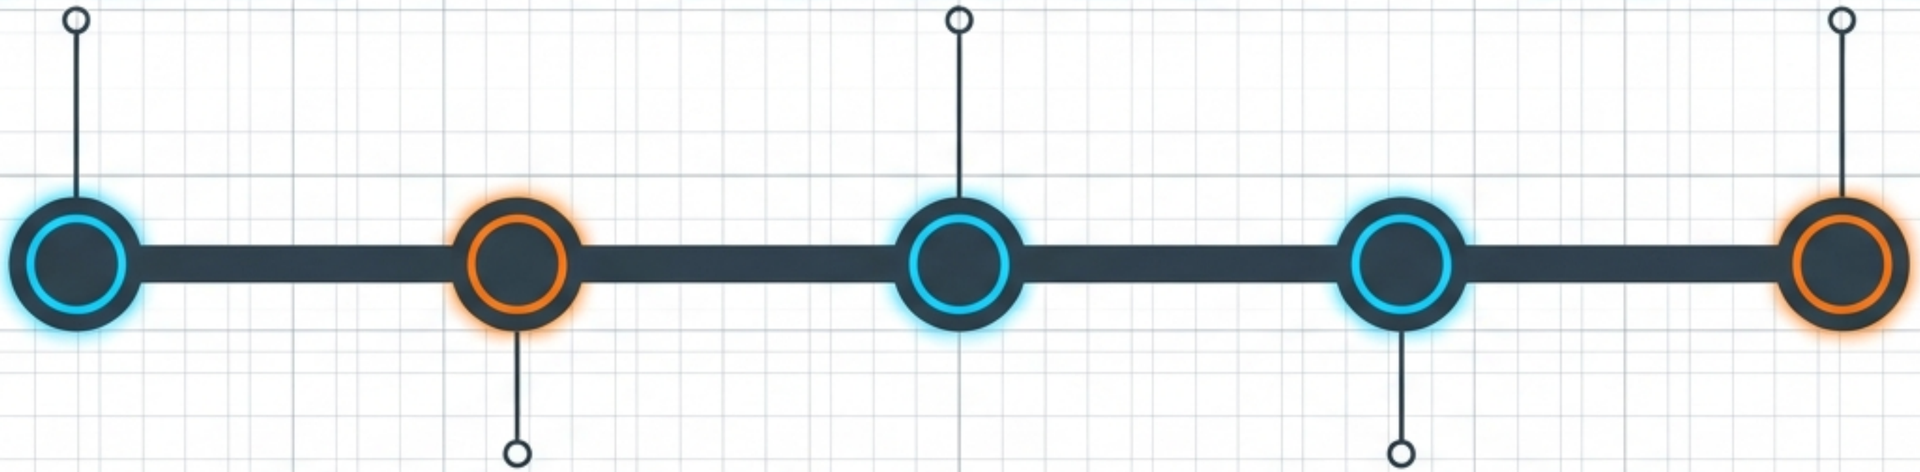
Aula 1. Análise Exploratória.
O Raio-X dos dados e a ilusão da média.

Aula 2. Otimização Univariada.
O problema matemático da lata cilíndrica.

Aula 3. Testes de Hipóteses.
A matriz de decisão sob incerteza.

Aula 4. NLP & Regressão Logística.
Transformando palavras em probabilidades.

Aula 5. Redes Neurais Profundas.
Minimizando o erro do cérebro artificial.

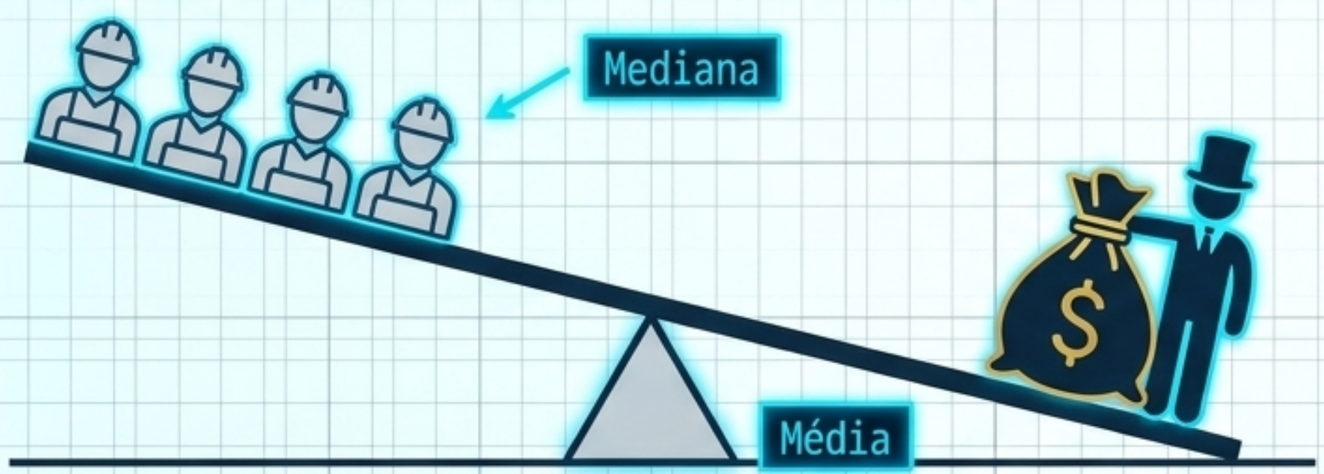


Gemini Notebook

AULA 1

A ilusão da média em dados assimétricos

Em distribuições com valores extremos (como salários), a média é puxada pelos outliers. A mediana divide os dados exatamente ao meio, revelando a verdadeira realidade da maioria.



Média $(\bar{x}) = \frac{\sum x_i}{n}$

Mediana (Q2) = Valor central dos dados ordenados

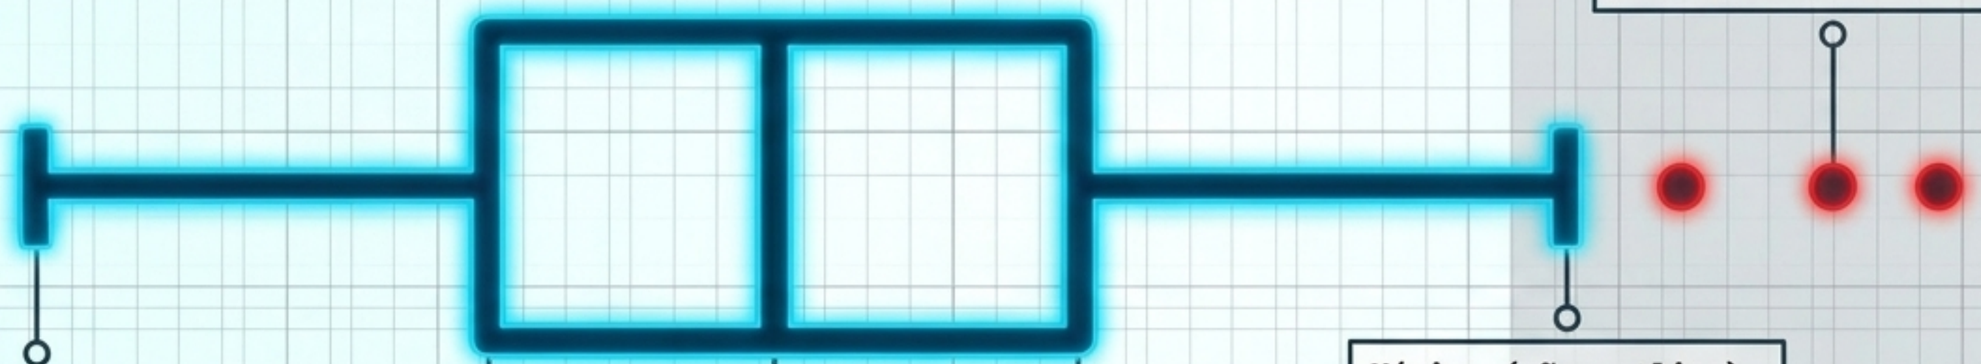
O Ponto de Corte.

Para dividir 230 funcionários entre salários Altos e Baixos, a professora Cibele Russo utiliza a mediana. Isso garante dois grupos balanceados, independentemente do salário do CEO.

Gemini Notebook

AULA 1

A anatomia do boxplot e a detecção matemática de anomalias



Outliers.
Valores extremos e possivelmente anômalos.

Mínimo (não-outlier).
O menor valor dentro do limite aceitável.

Q1 (25%).
O primeiro quartil.

Q2 (Mediana).
50% dos dados estão abaixo desta linha.

Q3 (75%).
O terceiro quartil.

Máximo (não-outlier).

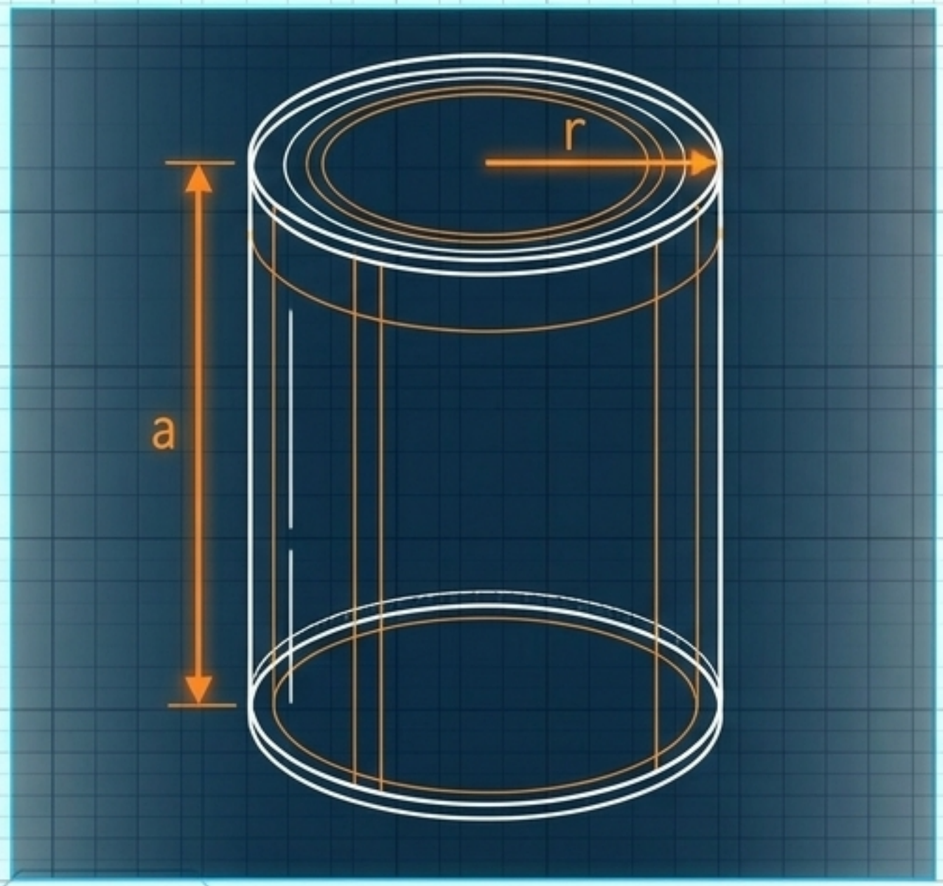
Regra do Outlier: $> Q3 + (1.5 \times IIQ)$
(Sendo $IIQ = Q3 - Q1$)

Gemini Notebook

AULA 2

Modelagem de decisão: o problema da lata cilíndrica

O objetivo da indústria é minimizar o custo (Área de metal) mantendo o produto exato (Volume fixo de 16π).



The Constraint

$$\text{Volume } (V) = \pi \cdot r^2 \cdot a = 16\pi \quad \Rightarrow \quad a = \frac{16}{r^2}$$

Substituindo a altura (a) na função objetivo, transformamos um problema de duas variáveis em uma otimização univariada:

The Objective

$$\text{Área } (A) = 2\pi \cdot r^2 + 2\pi \cdot r \cdot a$$

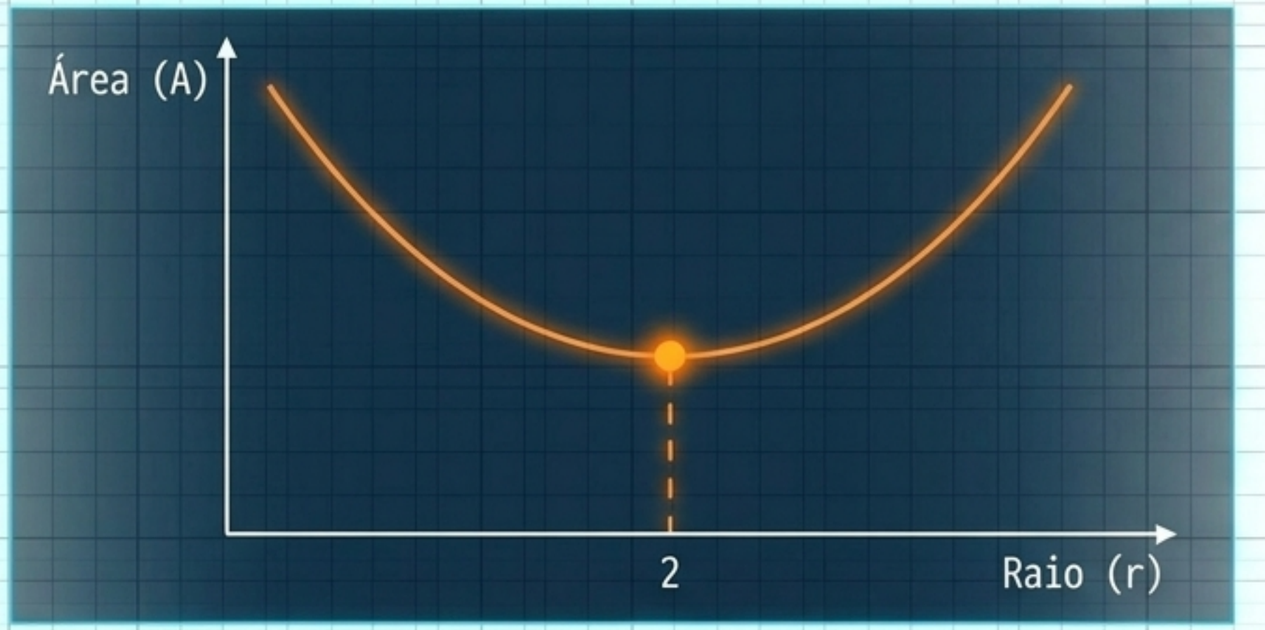
$$A(r) = 2\pi \cdot r^2 + \frac{32\pi}{r}$$

Gemini Notebook

AULA 2

Encontrando o ótimo matemático através da derivada

O custo mínimo ocorre exatamente no ponto onde a inclinação da curva (a derivada) é zero.



$$dA/dr = 4\pi \cdot r - (32\pi / r^2) = 0$$
$$r^3 = 8 \Rightarrow r = 2 \text{ cm}$$

A Lata Perfeita.

Substituindo r=2, descobrimos que a=4. O design ideal exige que a altura seja exatamente o dobro do raio (a=2r).

```
scipy.optimize.minimize_scalar

// Na prática, algoritmos numéricos buscam esse ponto iterativamente sem precisarmos calcular derivadas à mão.
```

Gemini Notebook

AULA 3

Testes não provam a verdade, eles balizam a decisão

		Realidade	
Decisão do Juiz		Inocente (H0 Verdadeira)	Culpado (H0 Falsa)
	Absolve (Não Rejeita H0)	Decisão Correta.	Erro Tipo II (β) Falso Negativo (Absolver culpado).
	Condena (Rejeita H0)	Erro Tipo I (α) Falso Positivo (Condenar inocente). O nível de significância.	Decisão Correta.

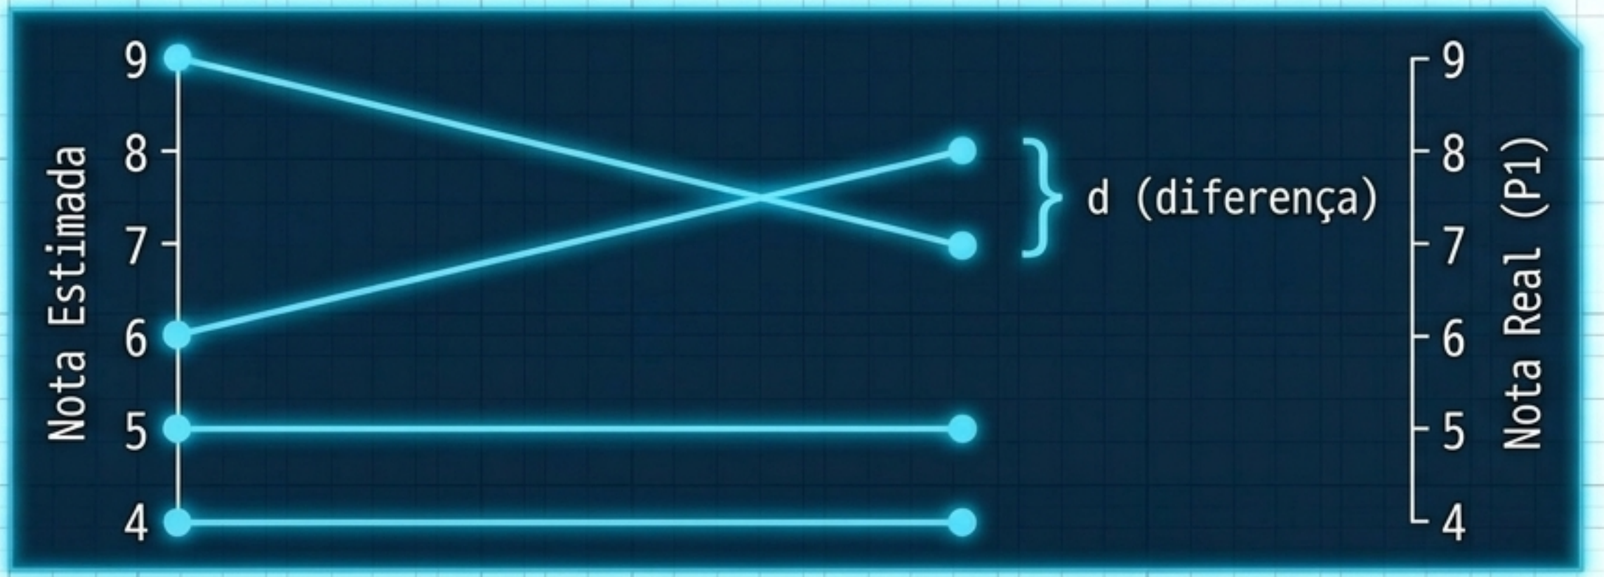
Na estatística, não dizemos "Aceito H0". Assumimos a inocência (H0) e procuramos evidências suficientes nos dados para rejeitá-la. O cobertor é curto: diminuir o Erro Tipo I sempre aumenta o Erro Tipo II.

Gemini Notebook

AULA 3

O Teste t Pareado na prática

O teste pareado é usado quando as medidas são dependentes (mesmo aluno antes e depois). Subtrair as notas cancela a variablidade individual, focando apenas no viés de estimativa.



H0: μd = 0 (Alunos acertam a própria nota)
tobs = ($\bar{d}$ - 0) / (sd / $\sqrt{n}$)

O Experimento

Na USP, tobs resultou em 0, gerando um P-valor de 1.0. Como P-valor > 0.05 (α), não rejeitamos H0.

É razoável supor que os alunos não têm viés sistêmico ao prever suas notas.

Gemini Notebook

AULA 4

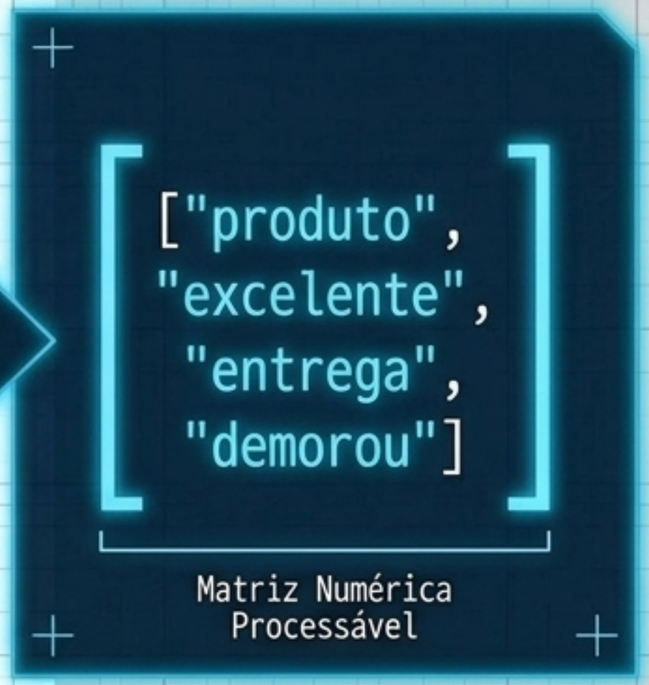
O pipeline de NLP: transformando texto em matemática



1. Coleta do texto bruto de avaliações de clientes.



2. Remoção de Stop Words (preposições e artigos frequentes que não agregam valor discriminatório).



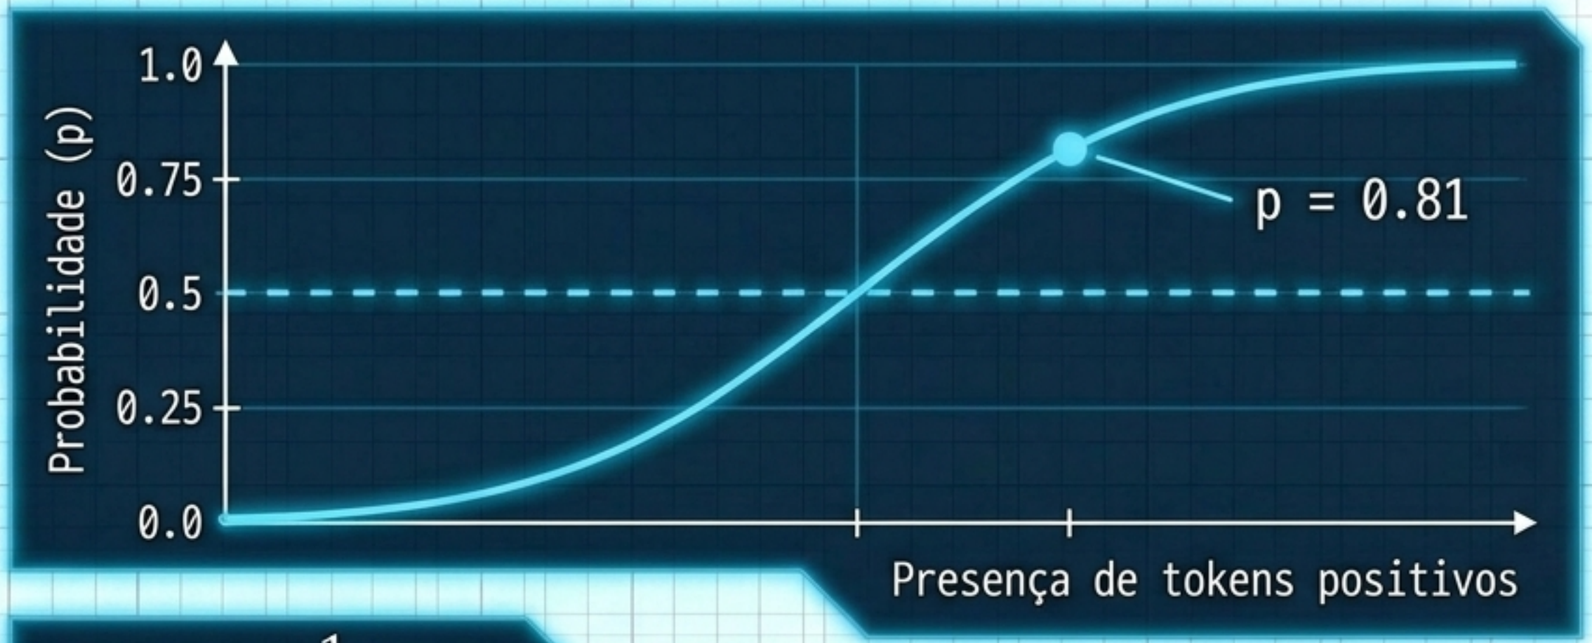
3. Tokenização (*Bag of Words*). A presença das palavras importantes vira uma matriz numérica processável.

Gemini Notebook

AULA 4

Regressão Logística: a probabilidade de um sentimento

A regressão logística modela a razão de chances. A curva em S garante que a previsão matemática sempre resulte em uma probabilidade percentual entre 0 e 1.



$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 X_1)}}$$

O Limiar de Decisão

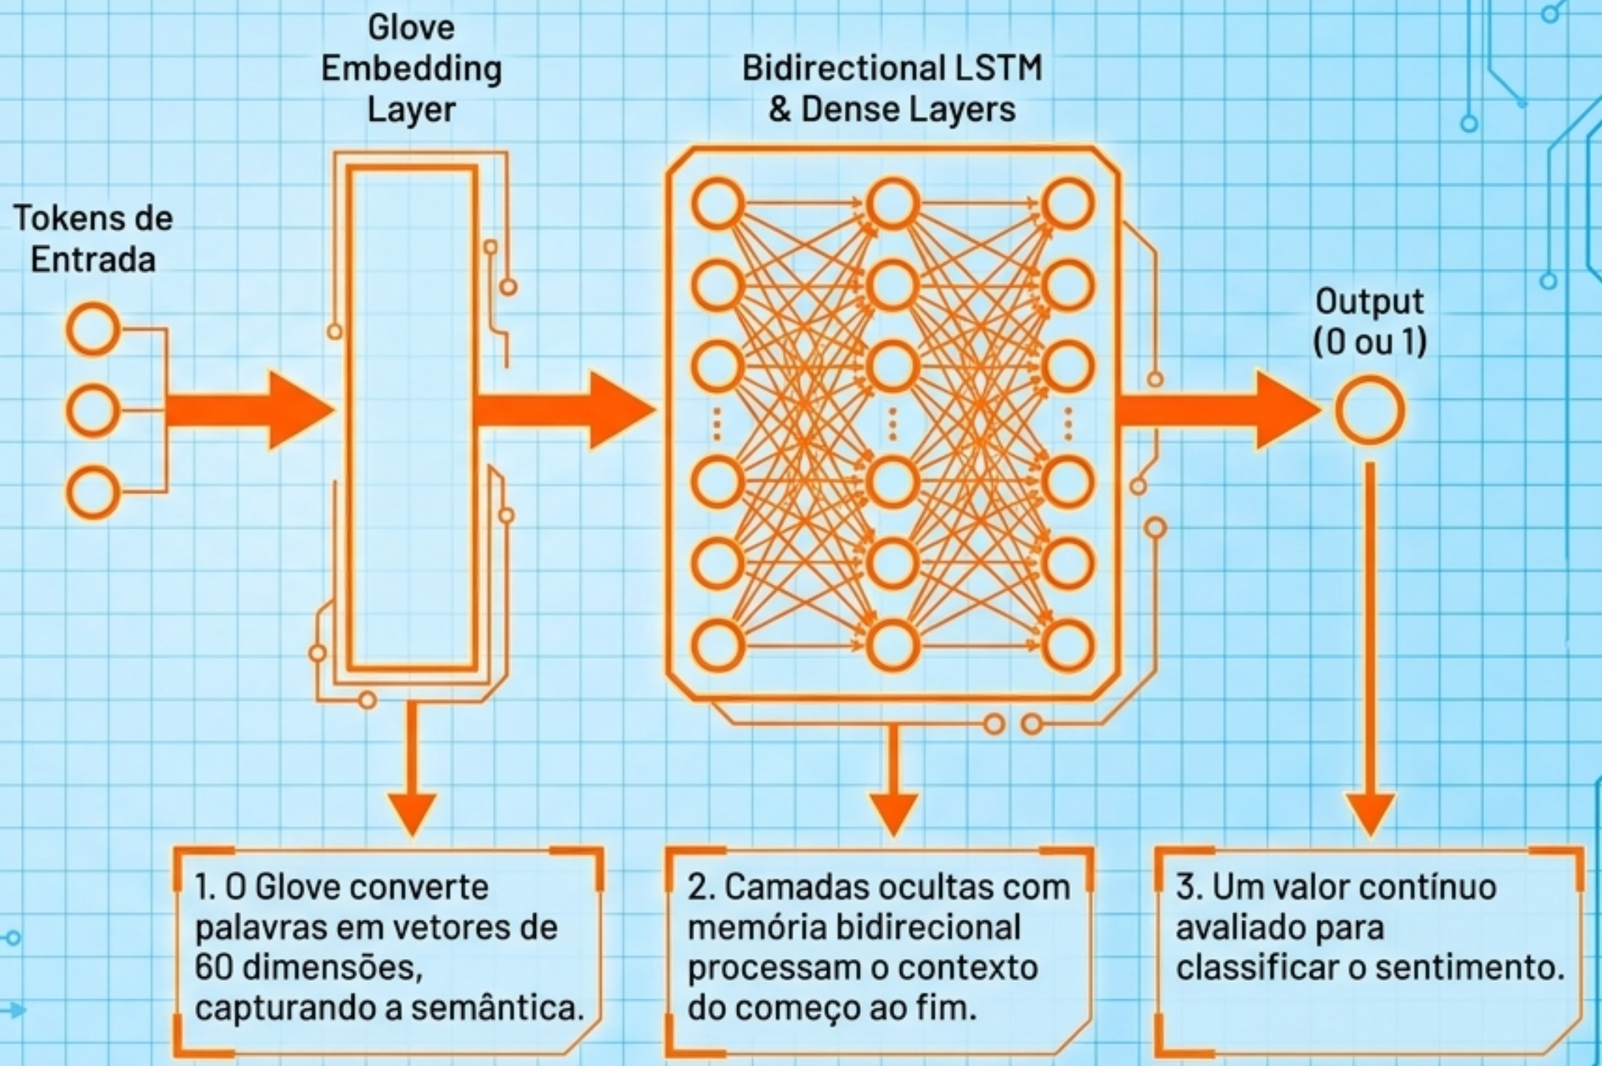
Se a palavra "excelente" (X1=1) for detectada, o preditor linear dispara.
A probabilidade calculada é p = 0.81 (81%).
Como ela cruza o limiar de 50%, o algoritmo classifica o comentário como Positivo.

Gemini Notebook

AULA 5

A arquitetura de uma rede neural profunda profunda

Redes neurais modernas não apenas contam palavras; elas compreendem o contexto transformando-as em arquiteturas de múltiplas camadas.

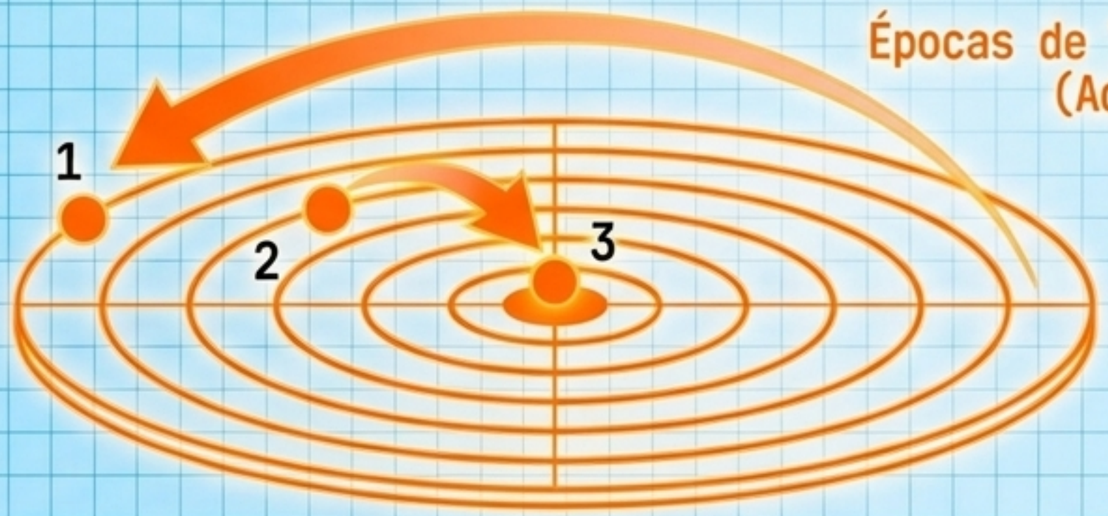


Gemini Notebook

AULA 5

Otimizando o cérebro artificial

Treinar uma rede neural é um problema massivo de minimização. A rede chuta, a função de perda mede o tamanho do erro, e o otimizador atualiza os pesos para melhorar o próximo chute.



Função de Perda (Entropia Cruzada Binária):
$Loss = - [y \cdot \ln(\hat{y}) + (1-y) \cdot \ln(1-\hat{y})]$

Reduzindo a Perda a Zero

Para uma frase positiva (y=1), se a rede prevê $\hat{y}=0.90$, o erro é 0.10.
O algoritmo de otimização (Adam) ajusta a rede iterativamente para empurrar esse erro a zero, sem decorar os dados de treino.

Gemini Notebook

SÍNTESE

O motor duplo da Ciência de Dados

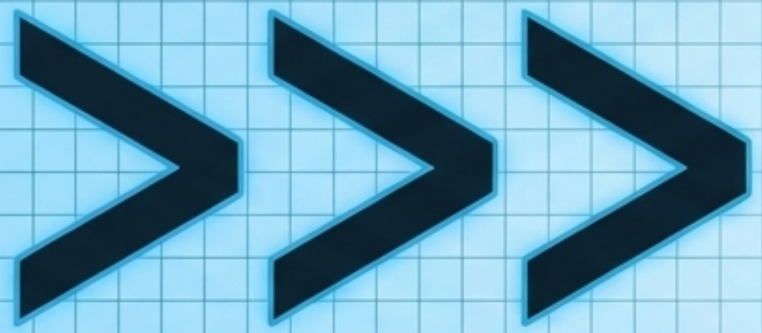
Estatística	Otimização
Qual é a pergunta? Como modelamos a incerteza e a variabilidade do mundo real?	**Qual é a pergunta?** Qual é a melhor decisão possível dadas as nossas restrições?
O que a disciplina faz? Estima parâmetros, testa hipóteses e constrói modelos preditivos.	**O que a disciplina faz?** Minimiza custos, maximiza lucros e ajusta algoritmos.

Onde se encontram? (Treinamento de IA)

A Estatística define a Função de Perda (a medida matemática do erro). A Otimização fornece os algoritmos que navegam no espaço de dados para encontrar os pesos que minimizam essa perda. Juntas, elas fazem a máquina aprender.

Gemini Notebook

Analise com Estatística. Decida com Otimização.



A ciência de dados real vai muito além de importar bibliotecas no Python. Exige compreender a matemática sob o capô para tomar decisões robustas em cenários complexos.

- Aulas práticas com Jupyter Notebooks estruturados.
- Interação direta e monitoria com pesquisadores USP.
- De testes não-paramétricos ao roteamento de veículos.

Aprofunde-se na teoria e na prática.
Conheça o curso de extensão em:
cdpo.icmc.usp.br

ICMC | Universidade de São Paulo

Gemini Notebook