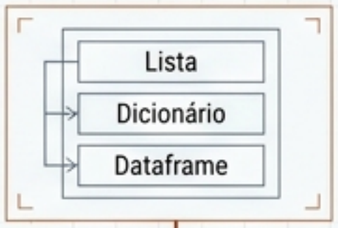
Fundamentos de Ciência de Dados: O Guia Definitivo

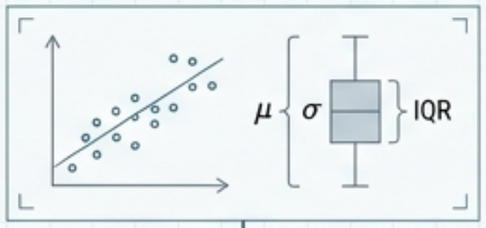
Fórmulas, Códigos e Diagramas Essenciais para Iniciantes

Uma arquitetura visual destilada:
do dado bruto ao modelo validado.



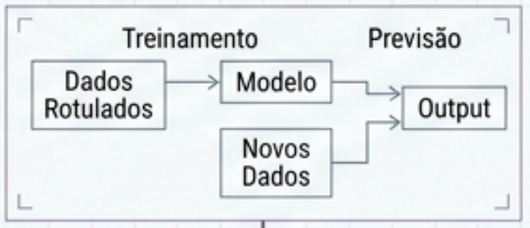
Python & Estruturas

```python
import pandas as pd
data = pd.DataFrame({
    'id': [1, 2, 3],
    'value': [10, 20, 30]
})
```



Análise Exploratória (EDA)

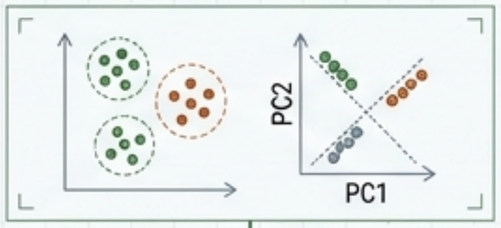
```python
data.describe()
data.hist(bins=10, figsize=(10, 6))
# Correlação: data.corr()
```



ML Supervisionado

$$y = \beta_0 + \beta_1 X + \varepsilon$$

```python
from sklearn.linear_model import LinearRegression
model = LinearRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
# y = β₀ + β₁X + ε
```

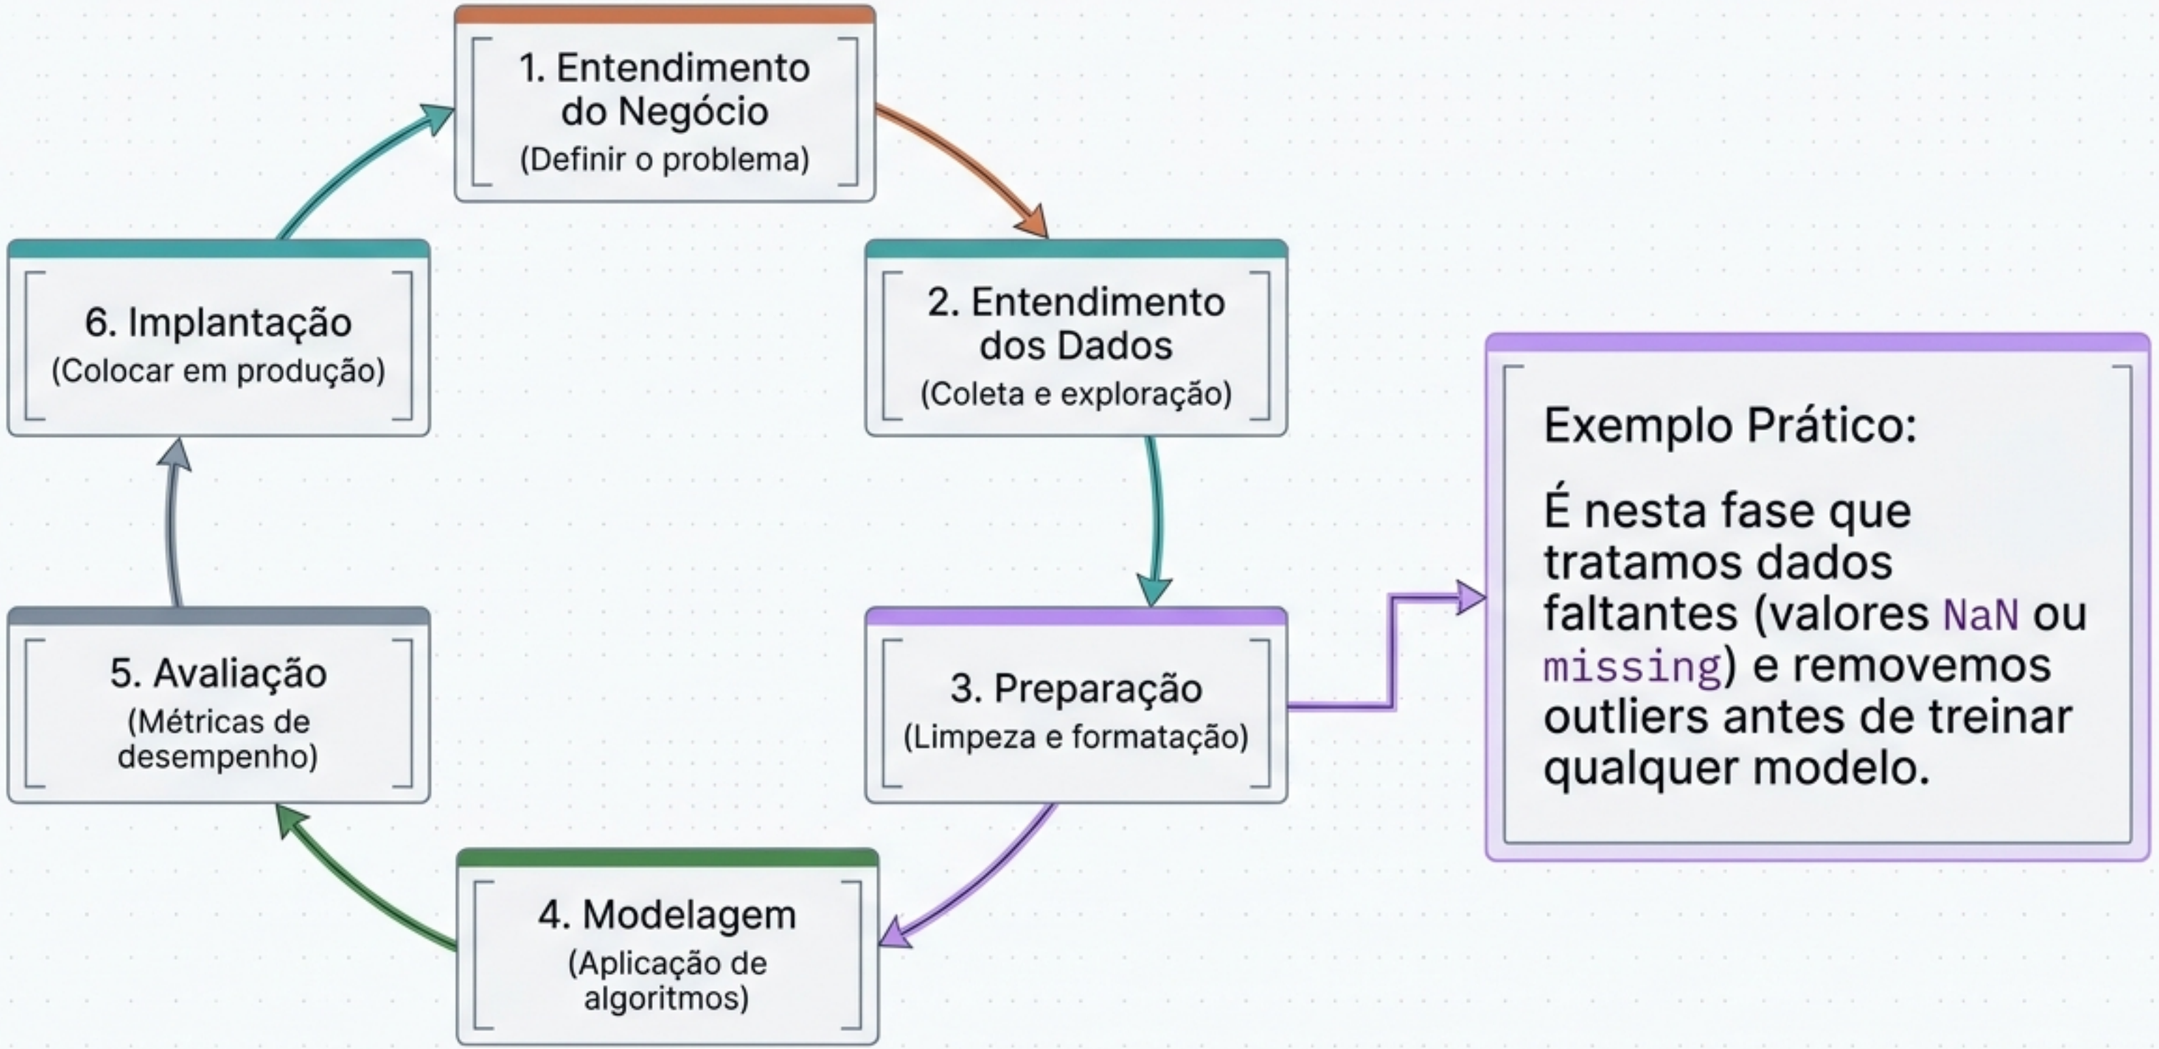


ML Não Supervisionado

```python
from sklearn.cluster import KNeans
kmeans = KMeans(n_clusters=3)
kmeans.fit(X_data)
labels = kmeans.labels_
# PCA: components_
```

Gemini Notebook

A Bússola do Cientista: O Método CRISP-DM



Gemini Notebook

Fundamentos de Python: Estruturas Nativas

Estrutura	Propriedades	Sintaxe	Exemplo
`Lista [ ]`	Ordenada | Mutável | Aceita repetição	`[ ]`	`frutas = ['maçã', 'banana', 'maçã']`
`Tupla ( )`	Ordenada | Imutável | Protege dados	`( )`	`coordenadas = (10, 20)`
`Set { }`	Não ordenada | Mutável | Sem repetição	`{ }`	`ids_unicos = {1, 2, 3}`
`Dict {k: v}`	Pares Chave-Valor | Mutável | Busca rápida	`{ : }`	`aluno = {'nome': 'Ana', 'idade': 25}`

⚠ Regra de Ouro: Use `Sets` para remover duplicações de uma lista instantaneamente, e `Dicts` para simular o formato `JSON`.

Gemini Notebook

O Motor dos Dados: Numpy vs. Pandas

NumPy

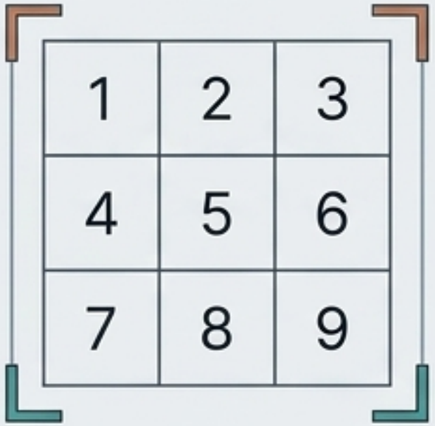
Foco: Álgebra Linear e Computação Numérica.

Estrutura: Arrays multidimensionais.

```
np.array([1, 2, 3])
```



Vetor (1D Array)



Matriz (2D Array)

Pandas

Foco: Manipulação de Dados Tabulares.

Estrutura: DataFrames (Tabelas) e Series (Colunas).

```
df.read_csv('dados.csv')
```

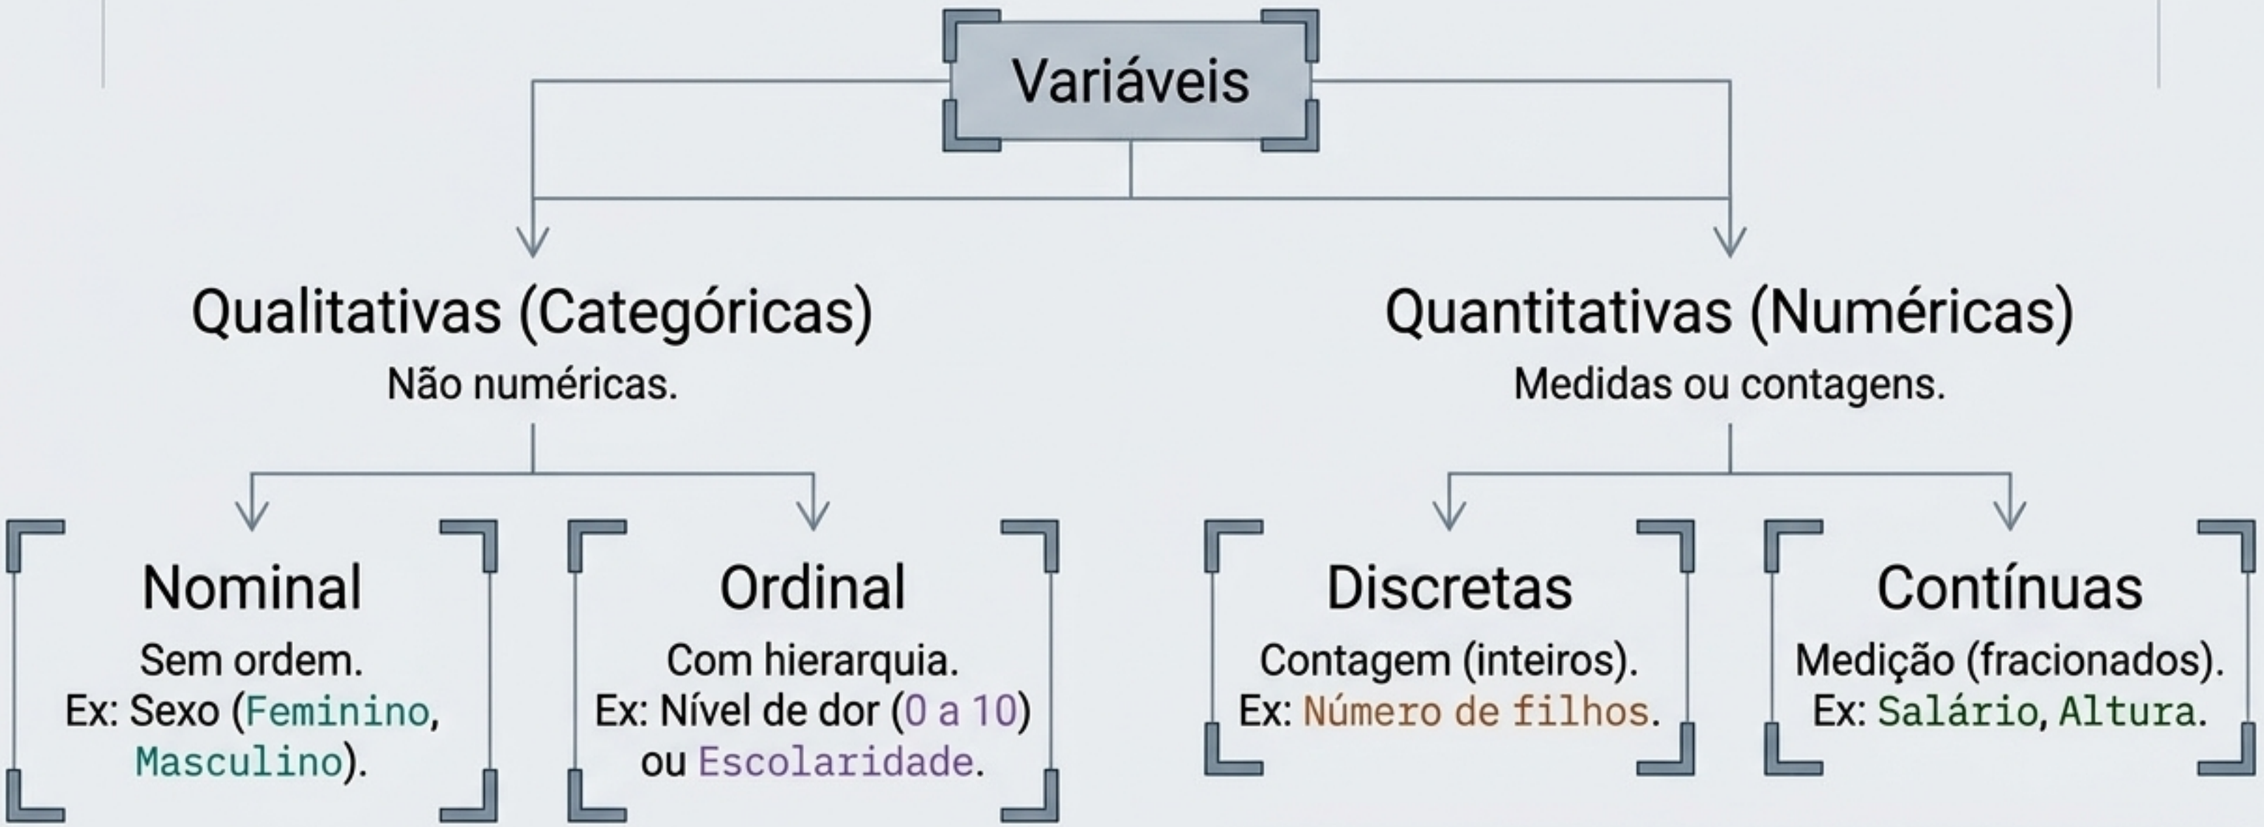
Variáveis / Atributos

Observações / Instâncias

ID	Nome	Idade	Salário
1	Ana	28	5000
2	Carlos	35	6200
3	Beatriz	42	7800
...	...	...	...
...	...	...	...

Gemini Notebook

Classificação das Variáveis: A Natureza dos Dados



⚠ **Atenção:** A escolha do gráfico ou do algoritmo de Machine Learning depende diretamente da natureza da sua variável.

Gemini Notebook

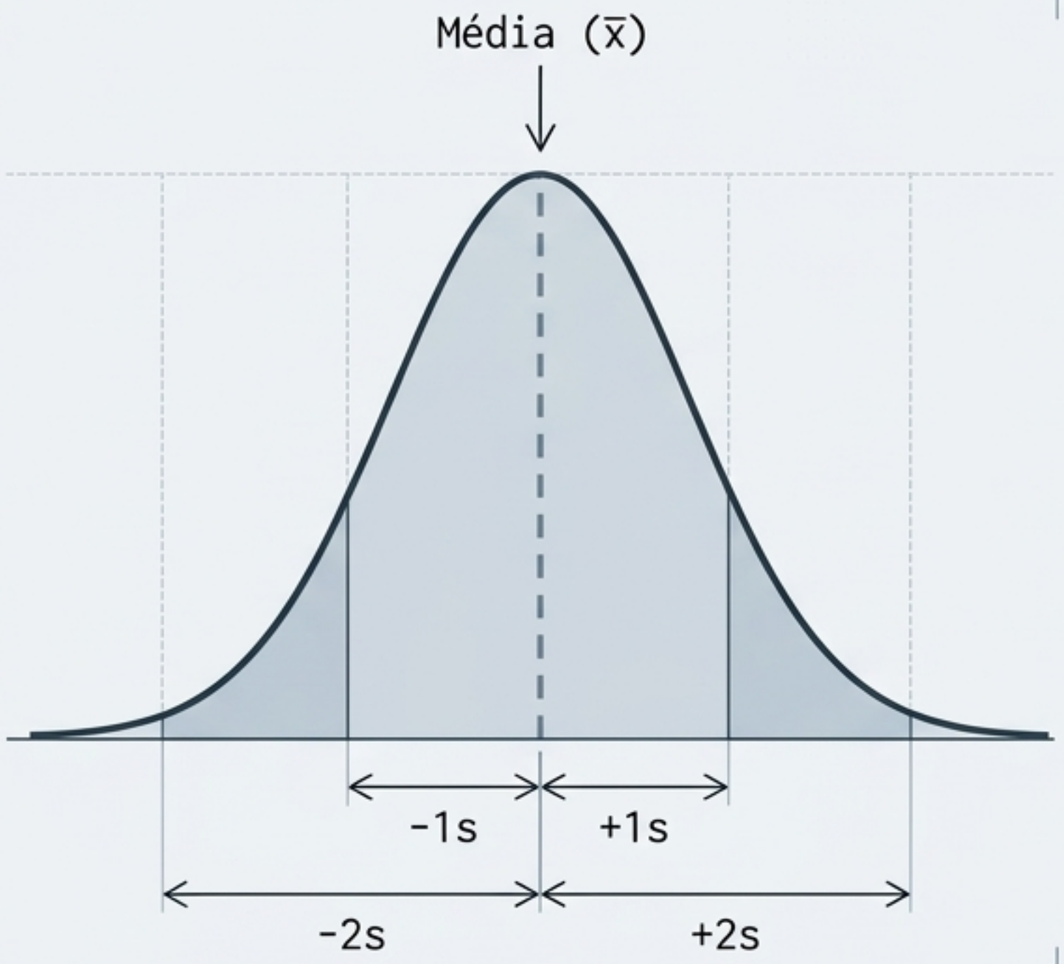
Estatística Descritiva: Posição e Dispersão

Posição (Onde os dados se concentram)

- **Média**: O centro de gravidade ($\bar{x} = \frac{\sum x_i}{n}$)
- **Mediana**: O valor exato do meio (50%). Robusta contra outliers.
- **Moda**: O valor mais frequente.

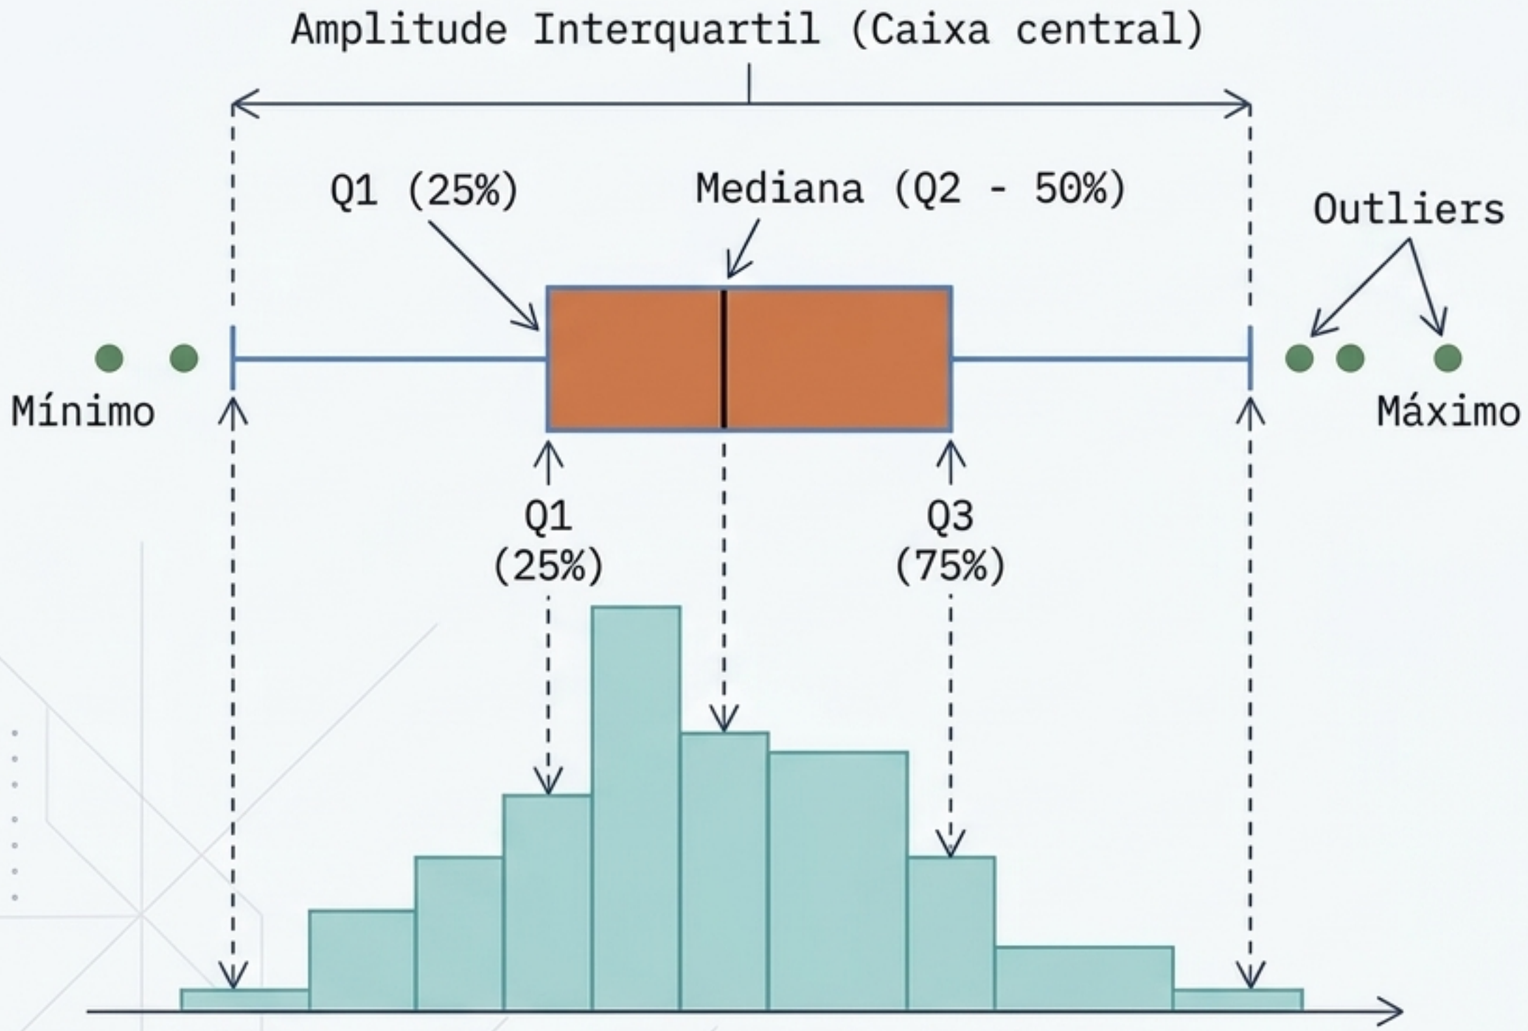
Dispersão (O quanto os dados variam)

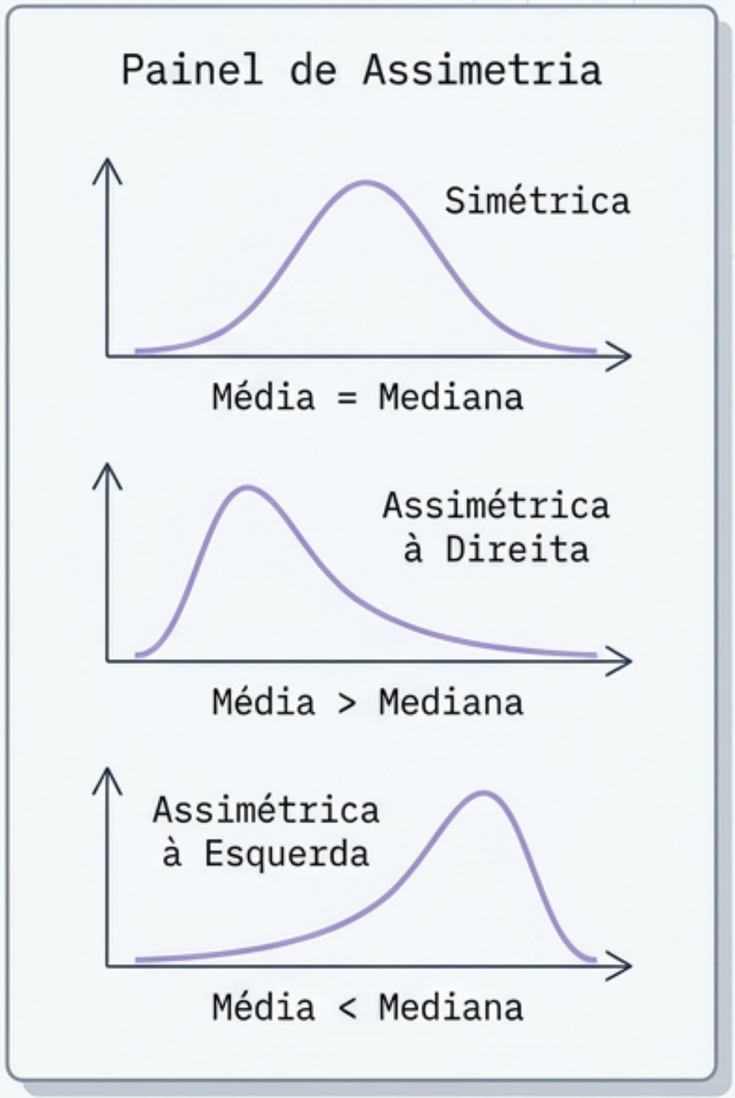
- **Variância**: Dispersão ao quadrado ($s^2 = \frac{\sum(x_i - \bar{x})^2}{(n-1)}$)
- **Desvio Padrão**: Variabilidade na unidade original ($s = \sqrt{s^2}$)
- **Coef. de Variação (CV)**: Adimensional ($CV = \frac{s}{\bar{x}}$)



Gemini Notebook

Dissecando Gráficos: Boxplot, Histograma e Assimetria



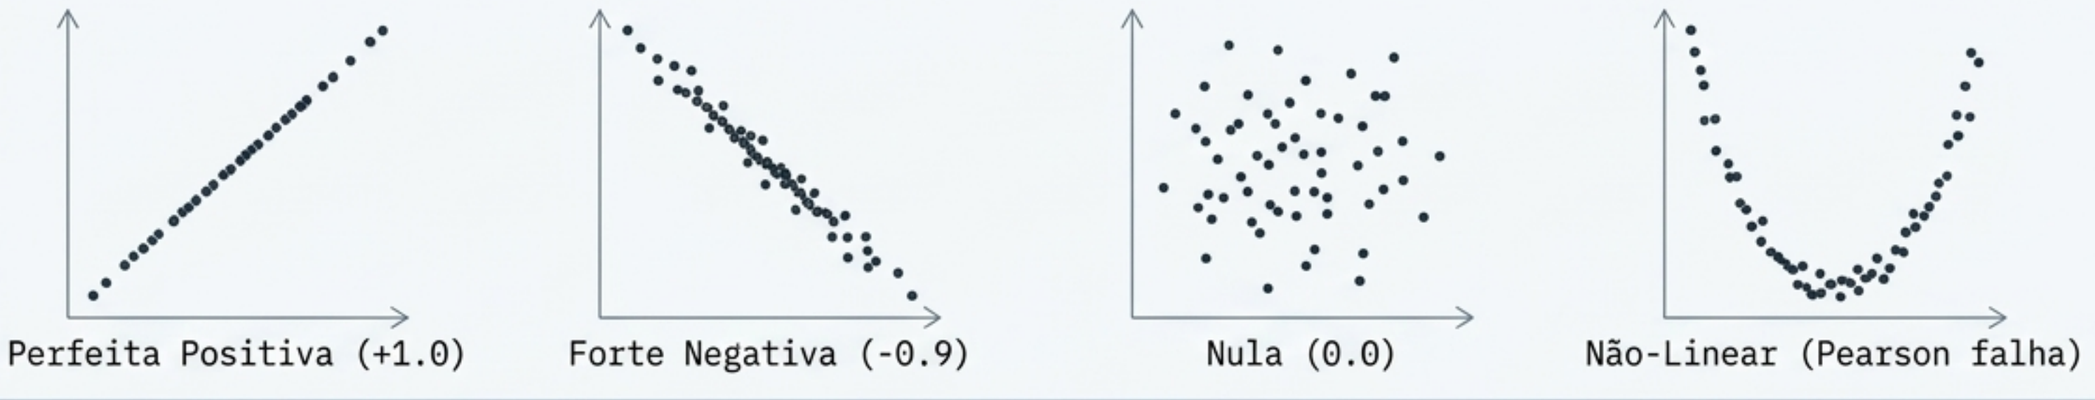


Gemini Notebook

Correlação: Associação Não é Causalidade

Métricas de Associação:

- Pearson (r): Mede relações estritamente lineares (-1 a +1).
- Spearman (ρ): Mede relações não-lineares (baseado em postos).



Correlações Espúrias: O consumo de margarina e a taxa de divórcios no Maine possuem 99,3% de correlação. Coisas andam juntas, mas uma não causa a outra!

Gemini Notebook

A Bifurcação: Machine Learning Supervisionado vs. Não Supervisionado



Supervisionado (Aprende com Professor)

Característica: Os dados possuem um Rótulo ou Target (Variável 'Y' conhecida).

Tarefas:
- **Classificação:** Prever categorias (Ex: Fraude ou Não Fraude).
- **Regressão:** Prever números (Ex: Preço de um imóvel).

Y (Target)

ID	Feature 1	Feature 2	...	...	Y (Target)
1	Feature 1	A1	...	Fraude	Fraude
2	Feature 2	A2	...	Fraude	Não Fraude
3	Feature 3	A3	...	Fraude	R$350k
4	Feature 4	A4	...	Fraudde	R$500k
5	Feature 5	A5	...	Fraudde	R$500k



Não Supervisionado (Aprende Sozinho)

Característica: Os dados não possuem rótulo. O algoritmo busca padrões ocultos na matriz 'X'.

Tarefas:
- **Agrupamento** (Clustering): Criar grupos por similaridade.
- **Redução de Dimensionalidade:** Simplificar dados complexos.

Apenas X

ID	Feature 1	Feature 2	...	...
1	Feature 1	A1	...	Fraude
2	Feature 2	A2	...	Não Fraude
3	Feature 3	A3	...	R$350k
4	Feature 4	A4	...	R$500k
5	Feature 5	A5	...	R$500k

Gemini Notebook

Algoritmos de Distância: O Método KNN

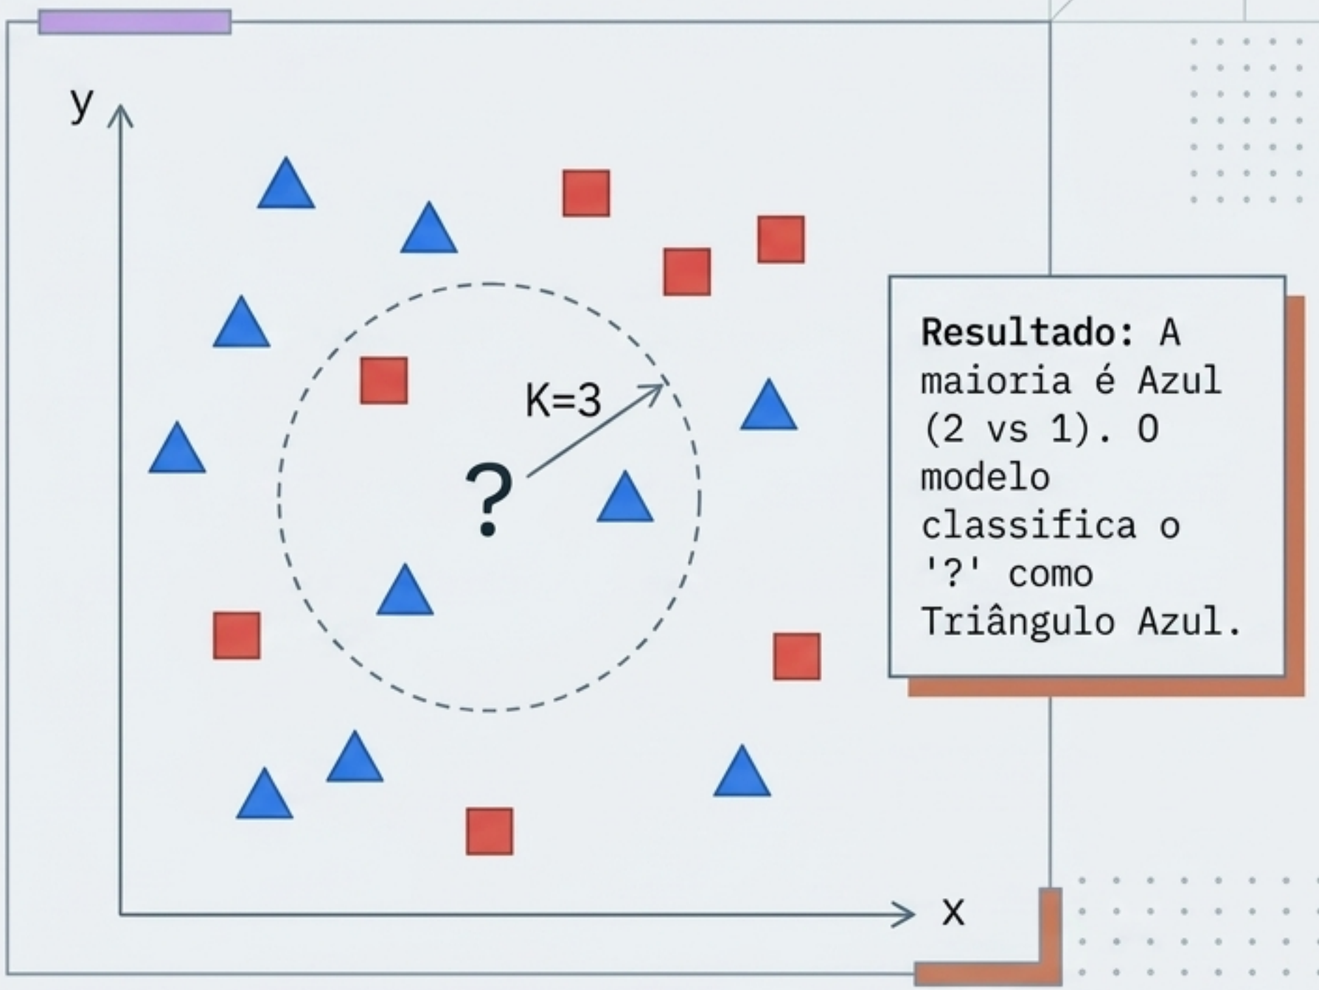
Conceito (K-Nearest Neighbors):

- Aprendizado "preguiçoso" (Lazy Learning). Não cria uma equação, apenas memoriza os dados de treino.

- Classifica novos pontos com base na votação da maioria dos K vizinhos mais próximos.

A Matemática (Distância Euclidiana):

$$d = \sqrt{\sum (qi - pi)^2}$$

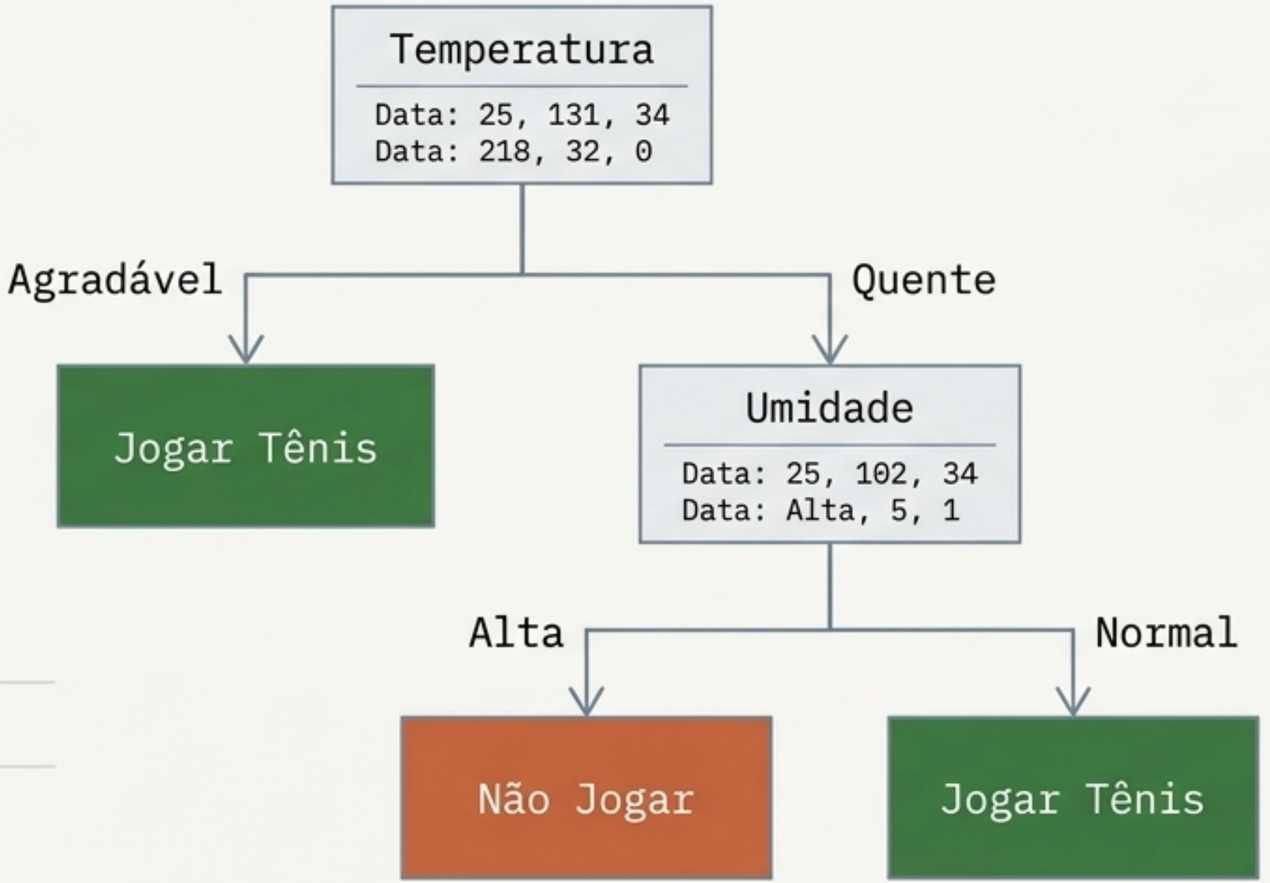


Resultado: A maioria é Azul (2 vs 1). O modelo classifica o '?' como Triângulo Azul.

Gemini Notebook

Algoritmos Baseados em Regras: Árvores de Decisão

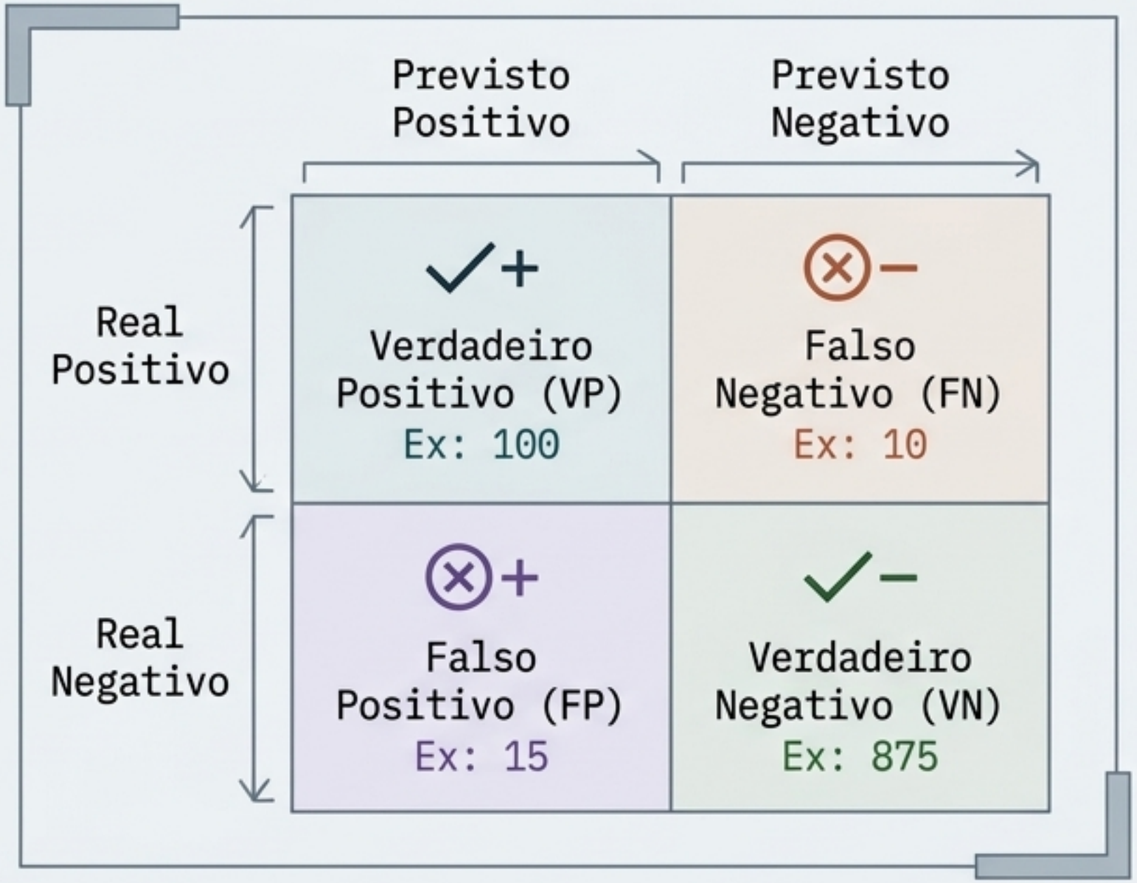
Conceito:
Divisão hierárquica do conjunto de dados por meio de perguntas binárias até atingir folhas puras. Altamente interpretável (Caixa Branca).



Nota Técnica:
Árvores podem ser usadas tanto para Classificação (rótulos categóricos) quanto para Regressão (valores numéricos).

Gemini Notebook

Avaliação de Desempenho e a Matriz de Confusão



Métricas de Classificação:

- **Acurácia:** Total de acertos / Total de casos.

  (VP + VN) / (VP + FN + FP + VN)

- **Precisão & Recall:** Lida com falsos alarmes e casos perdidos.

  Precisão = VP / (VP + FP)
  Recall = VP / (VP + FN)

Métricas de Regressão:

- MAE (Mean Absolute Error)
- RMSE (Root Mean Squared Error)
- R^2 (Coeficiente de Determinação)

⚠️ **Alerta Prático: A Armadilha da Acurácia**

Em datasets altamente desbalanceados (Ex: 99% transações normais, 1% fraude), um modelo que chuta 'Normal' 100% das vezes terá `99%` de acurácia, mas falhará miseravelmente em detectar fraudes reais.

Gemini Notebook

Validação e o Risco de Overfitting

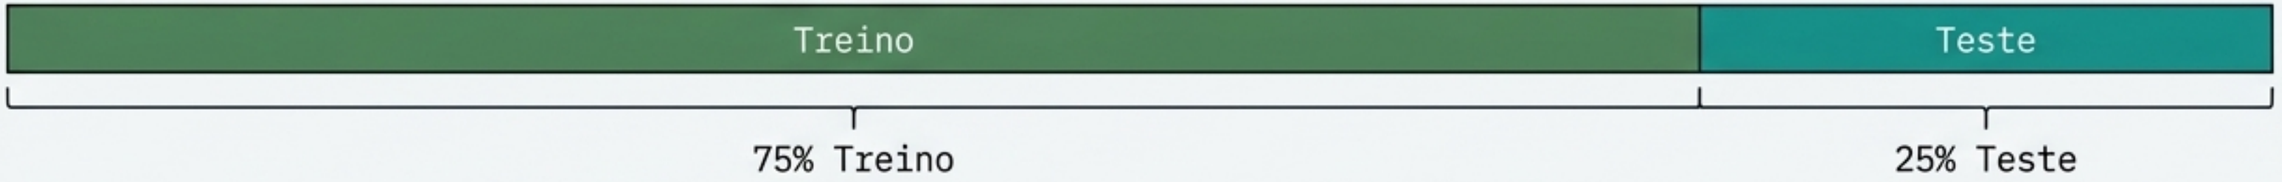
O Problema: Overfitting (Sobreajuste)

O modelo 'decora' a base de treino e erra feio em dados novos (mundo real).
E o vazamento de dados (Data Leakage).



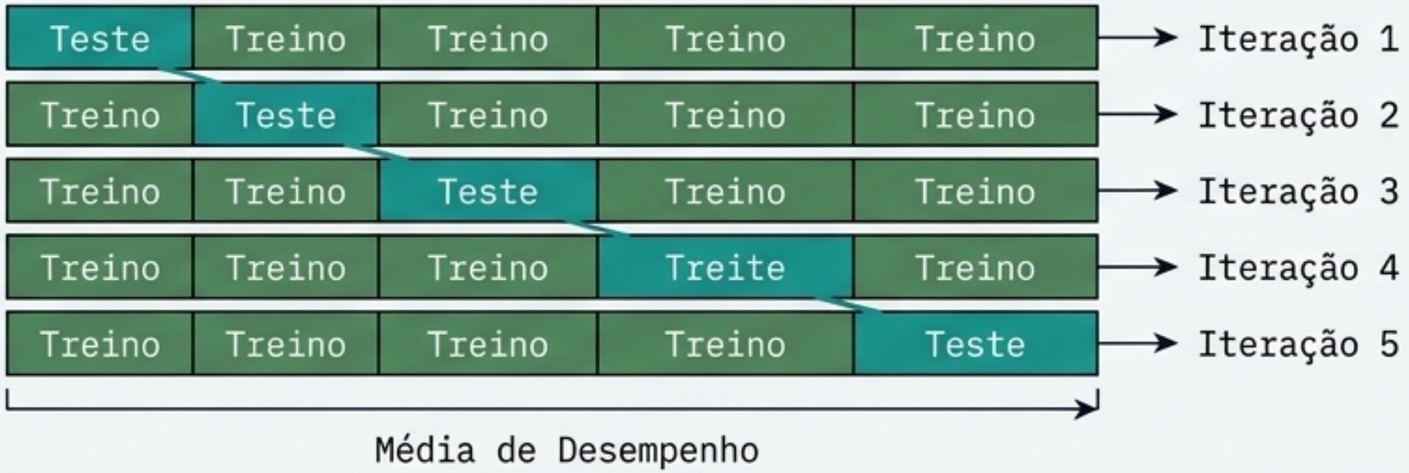
Solução 1: Holdout

Divisão simples: 75% Treino / 25% Teste.



Solução 2: K-Fold Cross Validation

O dataset é dividido em K pedaços (ex: 5 folds).
O modelo treina 5 vezes, variando o bloco de teste.
A média determina a qualidade.

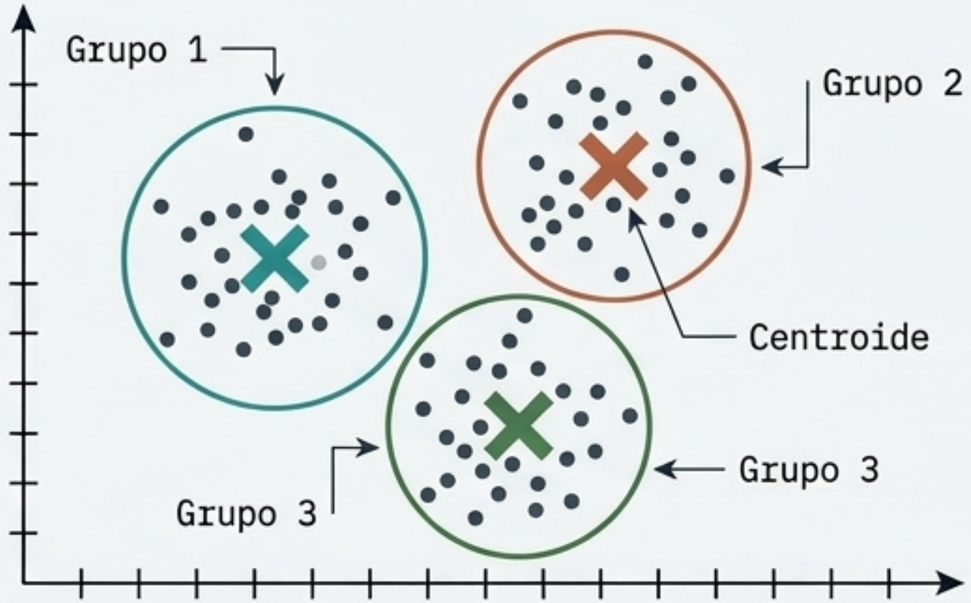


Gemini Notebook

ML Não Supervisionado: Descobrindo Padrões Ocultos

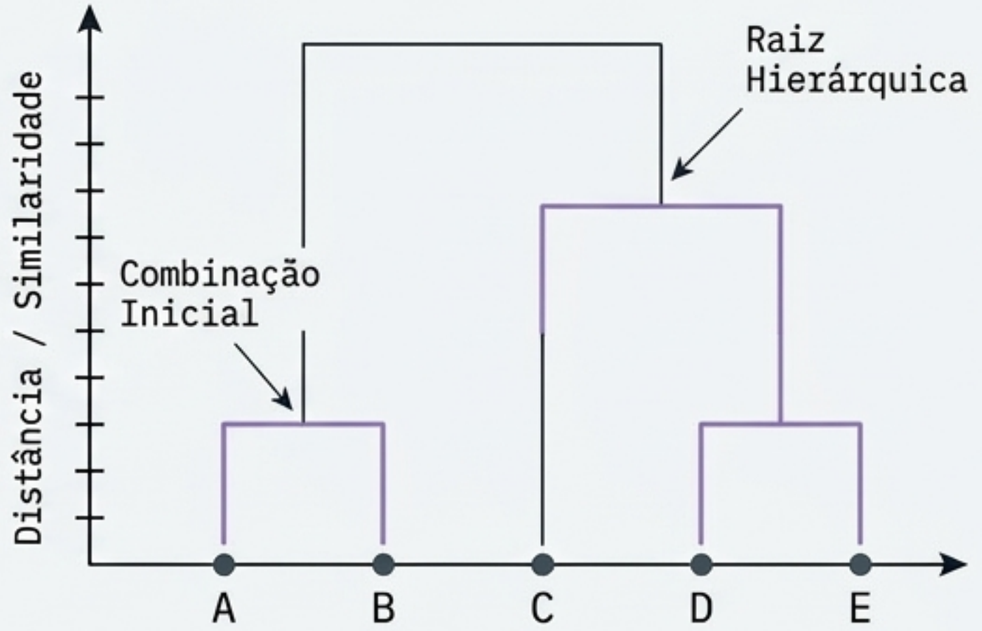
Algoritmo 1: K-Means

- **Conceito:** Particiona os dados em K grupos distintos.
- **Objetivo:** Minimizar a variância dentro de cada grupo.



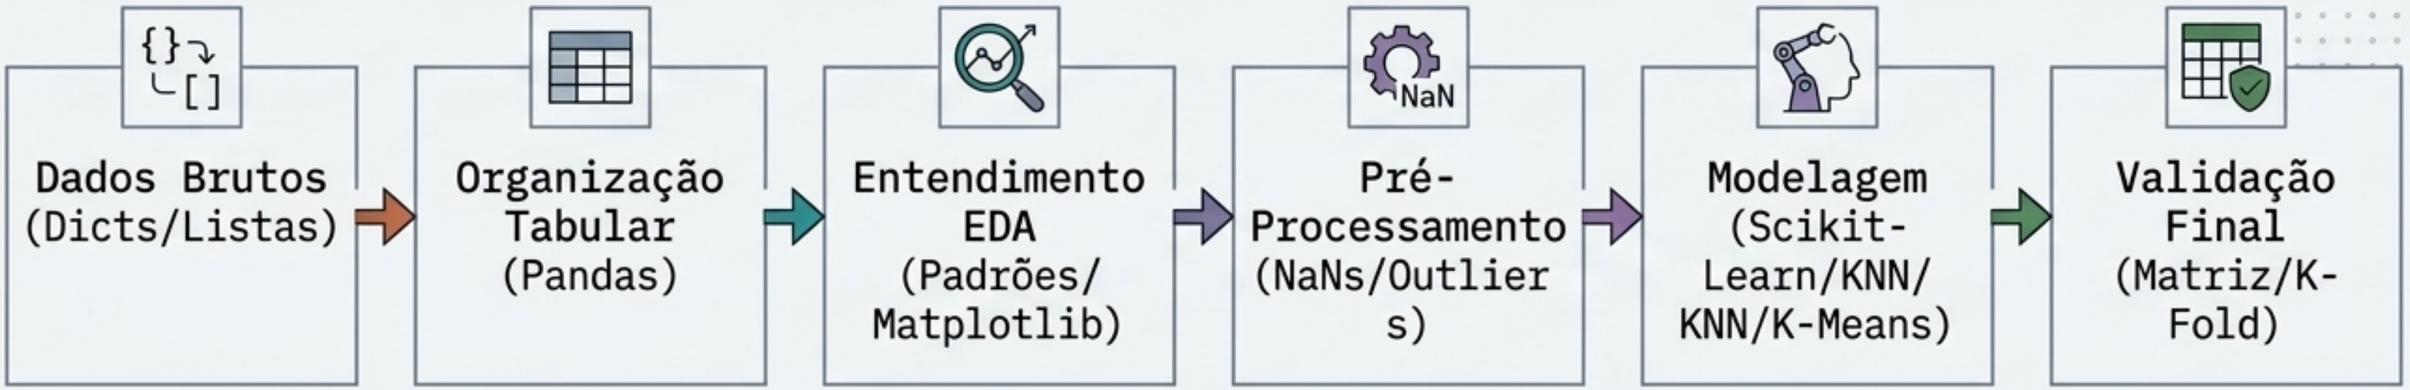
Algoritmo 2: Agrupamento Hierárquico

- **Conceito:** Não exige que K seja definido de antemão.
- **Visual:** O Dendrograma. Constrói uma hierarquia de similaridade.



Gemini Notebook

Síntese: A Jornada Completa do Dado



Ciência de Dados não é apenas código. É saber fazer a pergunta certa, escolher o algoritmo adequado à natureza da variável e saber interpretar matematicamente a margem de erro.

Gemini Notebook