MANUAL DE CAMPO DO DETETIVE DE DADOS



O Blueprint dos Dados

Guia **visual e definitivo** para exploração de dados estatísticos:
de variáveis simples a estruturas multidimensionais.

Gemini Notebook

A Trilha de Exploração



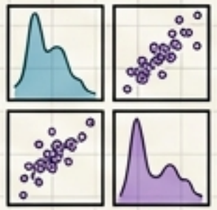
1. Anatomia Quantitativa (1D)

Explorando o formato, a posição e a dispersão de variáveis individuais.



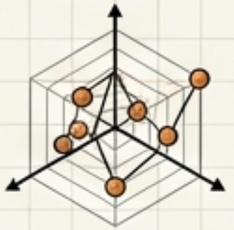
2. Concentração e Desigualdade

Medindo o acúmulo de variáveis usando Curvas de Lorenz e Índice de Gini.



3. A Matriz de Associação (2D)

Cruzando dimensões: testes, correlações e visualizações entre variáveis qualitativas e quantitativas.



4. Complexidade Multidimensional (N-D)

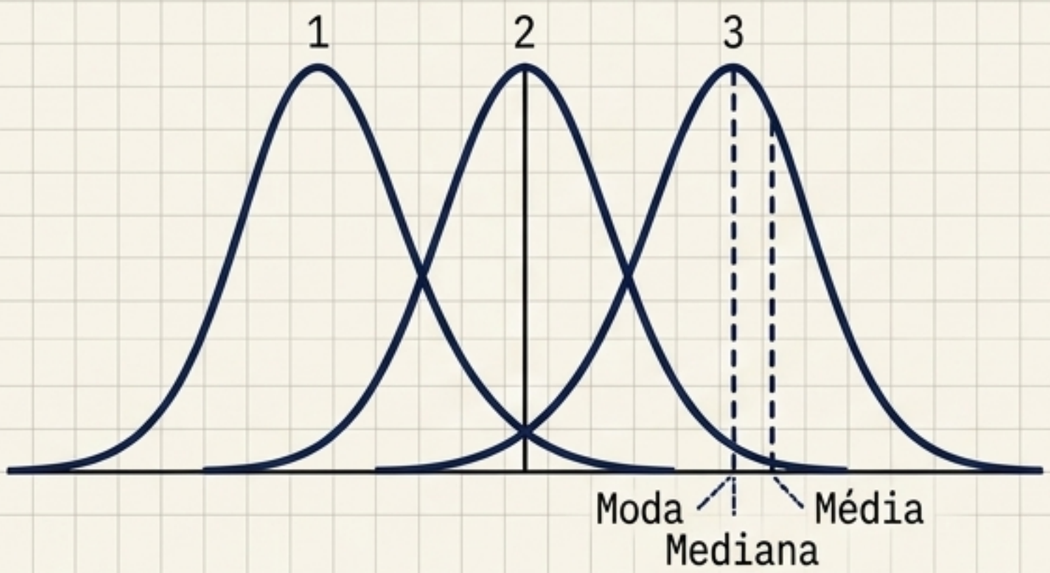
Estratégias avançadas para representar 3, 4 ou mais variáveis simultaneamente.

Gemini Notebook

BLOCO 1: DADOS QUANTITATIVOS

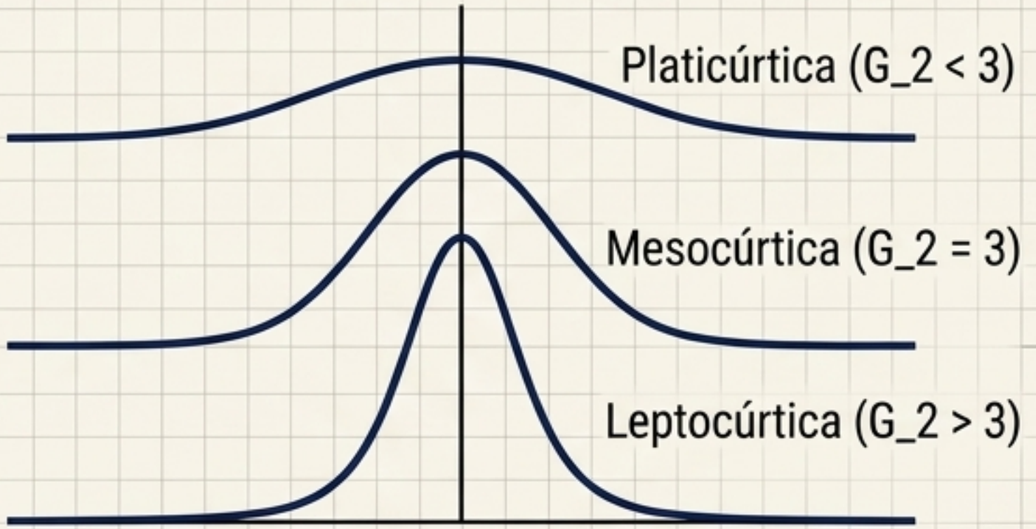
Medidas de Forma e Posição

Assimetria



- Assimetria Positiva (à direita): O "rabo" da distribuição puxa a média para cima. A mediana é mais resistente.

Curtose



- Curtose (Achatamento): Mede a concentração dos dados em relação à distribuição normal. A métrica de Excesso de Curtose usa G_2 - 3.

Fórmulas-chave para a variância e desvio padrão amostral:

$$S^2 = \sum(x_i - \bar{x})^2/(n-1)$$

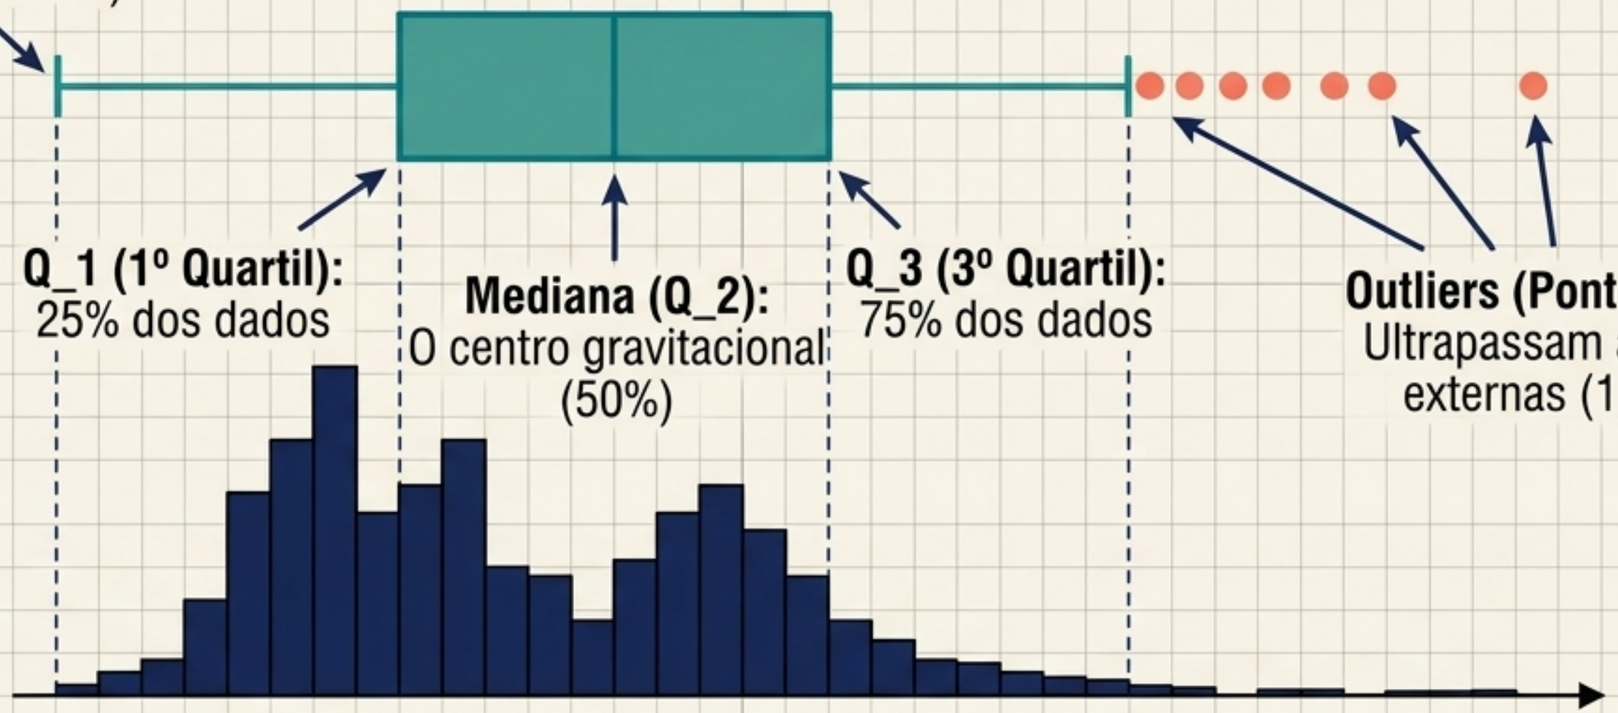
Gemini Notebook

BLOCO 1: DADOS QUANTITATIVOS

A Anatomia Gráfica: Boxplot vs. Histograma

Limite Inferior:
Observação mais baixa (não-outlier)

Amplitude Interquartil (IQR): Q_3 - Q_1
(Tamanho da caixa indica dispersão)



Q_1 (1º Quartil):
25% dos dados

Mediana (Q_2):
O centro gravitacional
(50%)

Q_3 (3º Quartil):
75% dos dados

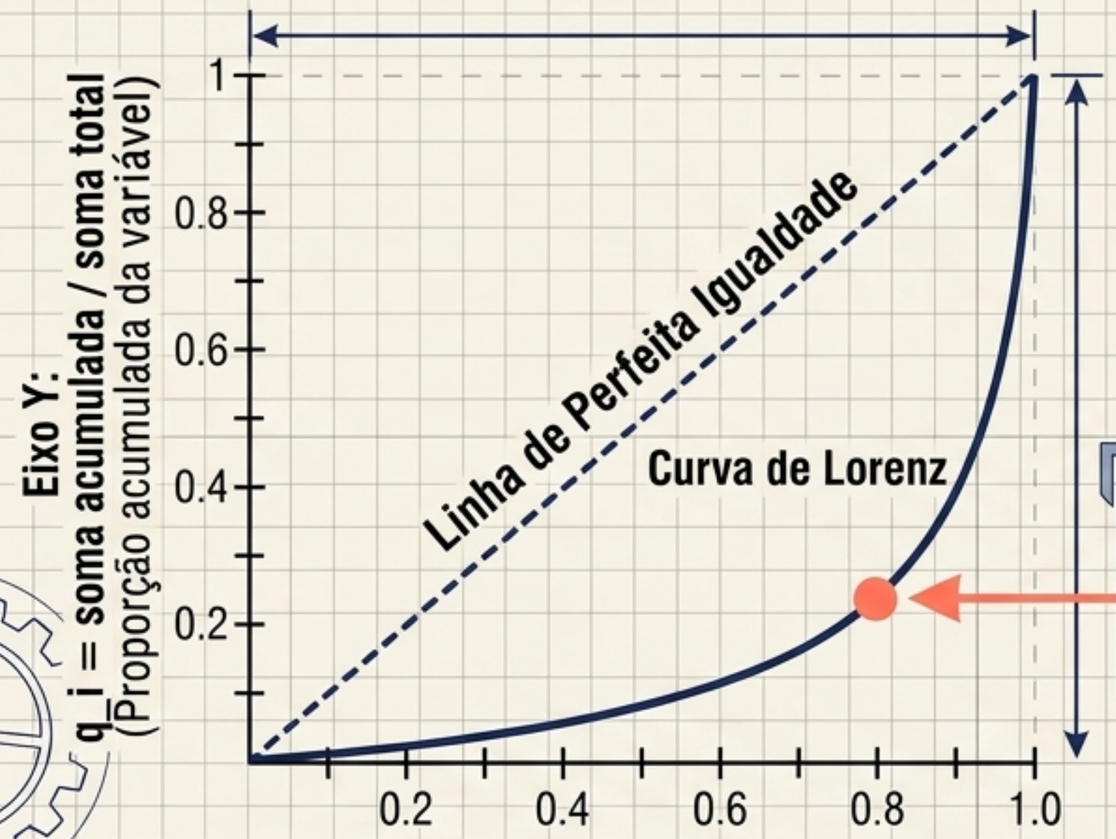
Outliers (Pontos atípicos):
Ultrapassam as barreiras externas (1.5 × IQR).

O **Boxplot** resume posição, dispersão e anomalias. O **Histograma** revela **Picos** e **Modas** ocultas (ex: distribuições bimodais).

Gemini Notebook

BLOCO 2:
CONCENTRAÇÃO

Dissecando a Curva de Lorenz



Lendo o gráfico:
80% da população detém apenas 20% da renda.

Curva de f_i: 80% da populaçado detém apenas hetieros 20% da Educato$_E$, linha de 20% da Y$_i$.

Curva de copocidade rroporção acumulada mais aporior atal de 100.

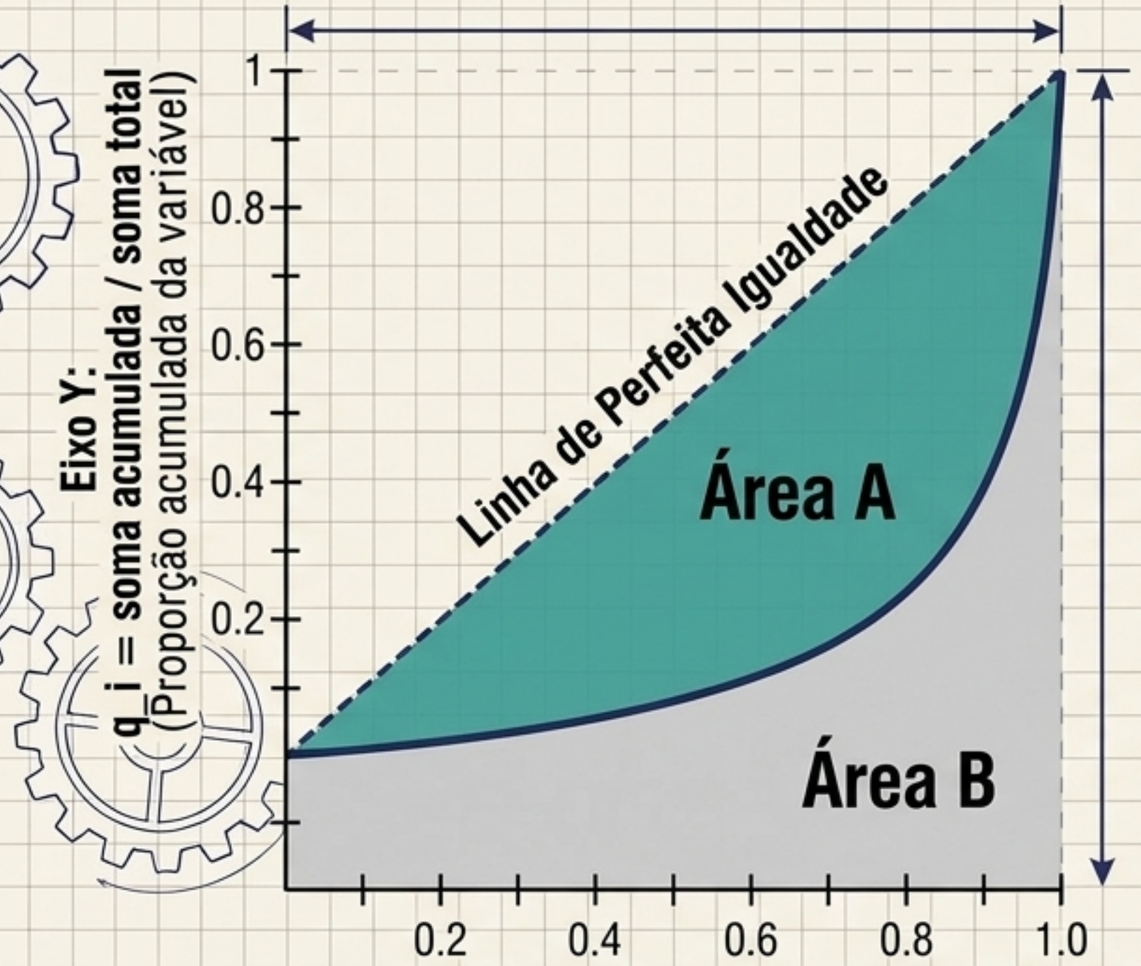
Reta ti de renda: aumente, acumlidada, 5% da ceolta e a curva da da renda.

Se a renda fosse dividida igualmente, cada indivíduo representaria uma fração idêntica da riqueza, e a curva de Lorenz seria a reta de 45º.

Gemini Notebook

BLOCO 2: CONCENTRAÇÃO

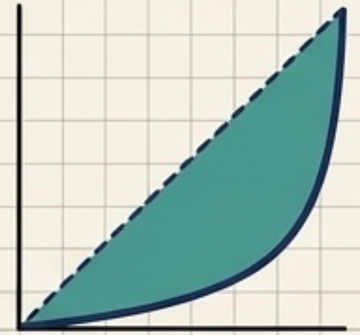
O Índice de Gini



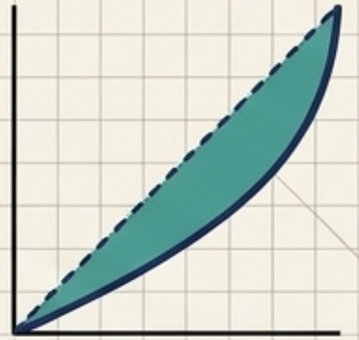
$$Gini = A / (A + B)$$

Mede estritamente a desigualdade
(0 = Perfeita Igualdade,
1 = Desigualdade Máxima).

Cenário 1: População do Brasil. Gini ≈ 0.60. Uma das maiores taxas de desigualdade, onde a curva "afunda" drasticamente para a base do gráfico.



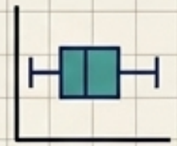
Cenário 2: 500 Bilionários (Top Forbes 2018). Gini = 0.41. Mesmo no topo da pirâmide global, há notável concentração.



Gemini Notebook

BLOCO 3:
ASSOCIAÇÃO

A Matriz de Decisão de Variáveis

Variável 1	Variável 2: Qualitativa	Variável 2: Quantitativa
Qualitativa	 - **Visuais:** Mosaico, Barras Empilhadas - **Teste:** Qui-Quadrado (χ^2) - **Tabelas:** Dupla Entrada (Contingência)	 - **Visuais:** Boxplot, Gráfico de Violino - **Teste:** ANOVA / Teste de Médias - **Métrica:** Decomposição da Variância (R^2)
Quantitativa	(Espelho da relação Qualitativa vs. Quantitativa)	 - **Visuais:** Gráfico de Dispersão (Scatterplot) - **Métrica:** Covariância, Correlação Linear de Pearson (r) - **Modelo:** Regressão Linear Simples

Gemini Notebook

BLOCO 3:
ASSOCIAÇÃO

Qualitativa vs. Qualitativa

Gráfico de Barras Empilhadas

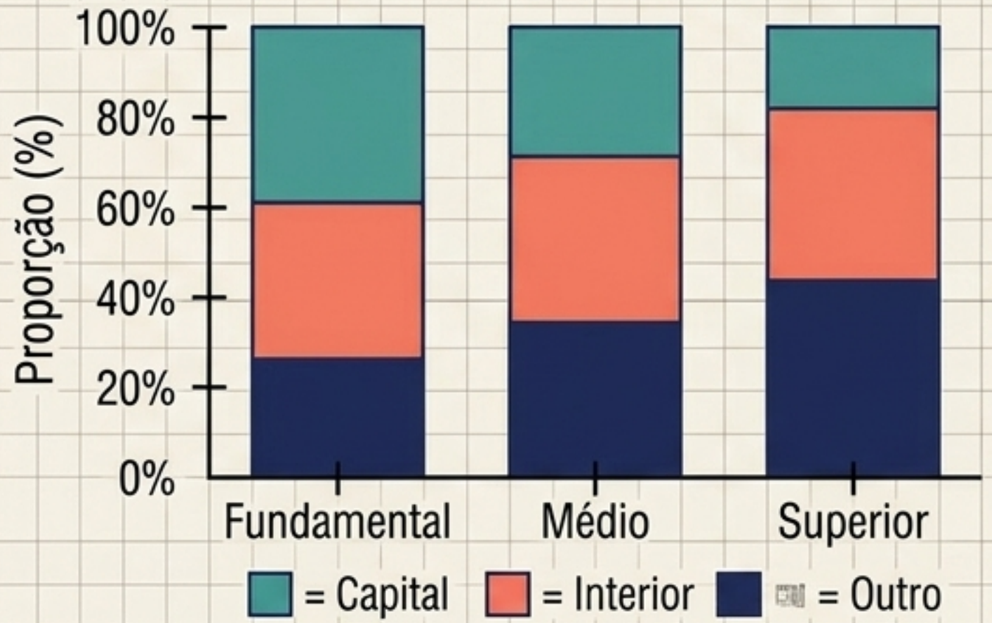
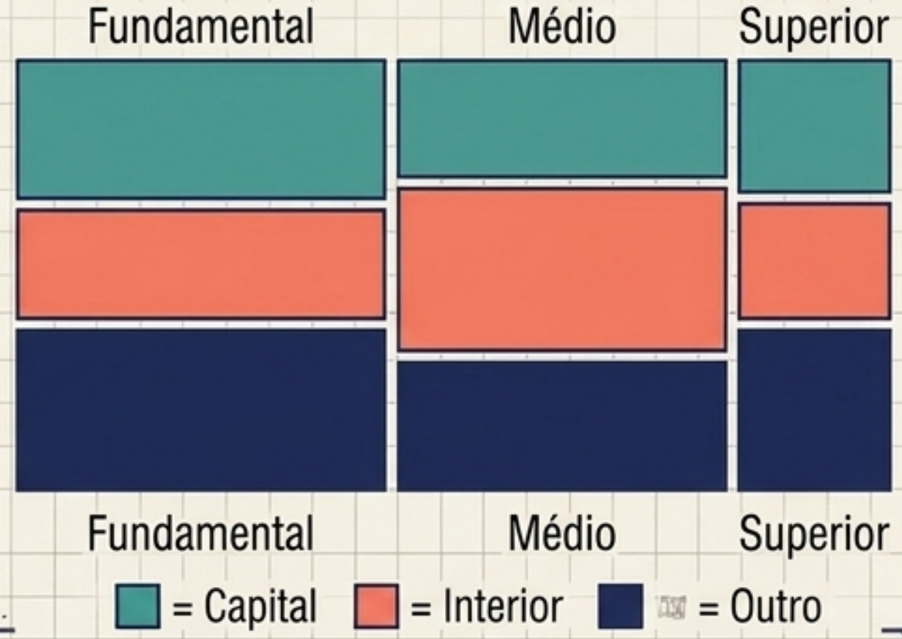


Gráfico de Mosaico (Mosaic Plot)



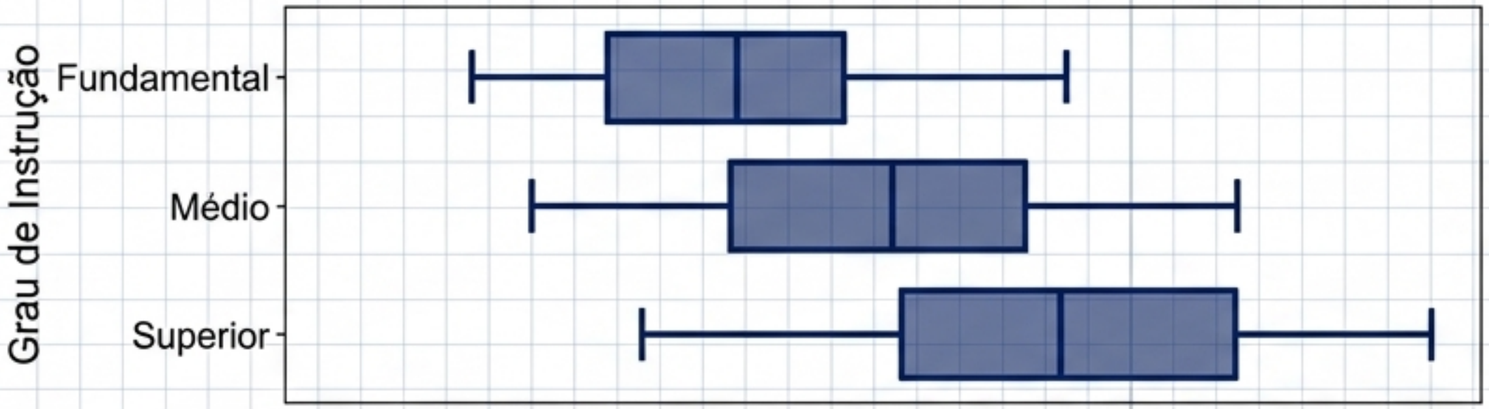
Independência vs. Associação: Se não houvesse associação, a divisão das barras menores (Região) seria estritamente proporcional em todos os níveis de Instrução. A variação visual comprova a dependência.

O **Teste Qui-Quadrado** (χ^2) compara as frequências observadas nos gráficos com as frequências esperadas caso as variáveis fossem perfeitamente independentes. Um Valor-P pequeno sinaliza forte associação.

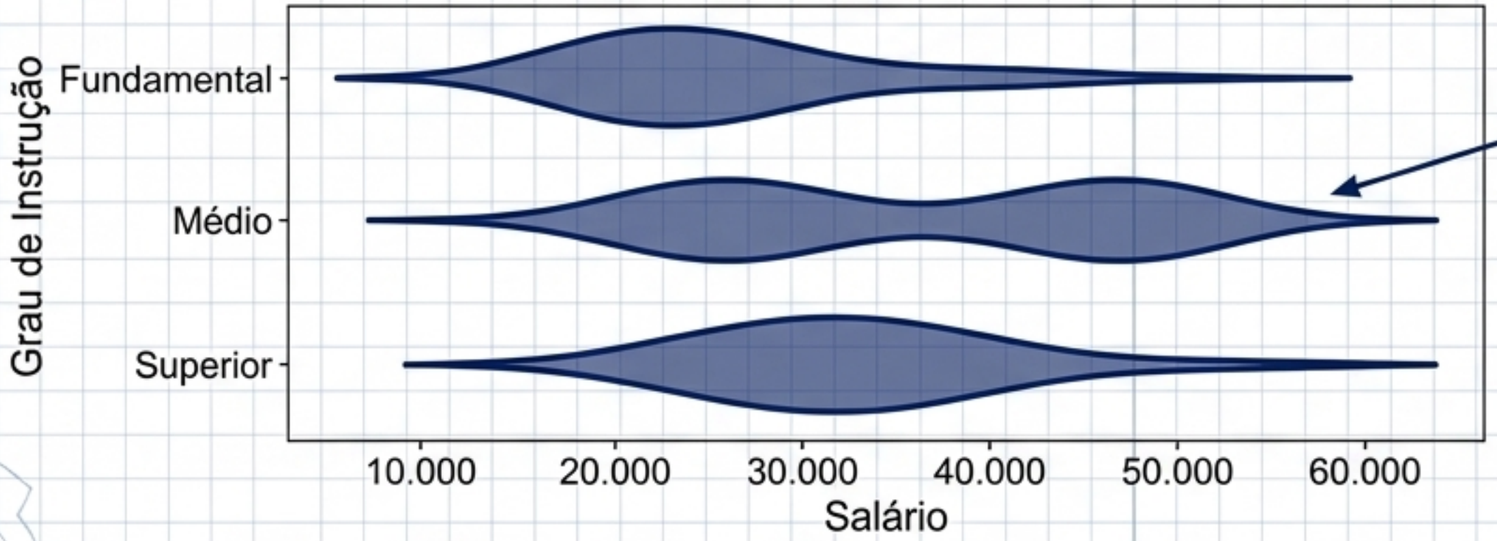
Gemini Notebook

BLOCO 3: ASSOCIAÇÃO

Quantitativa vs. Qualitativa



- **Intersecção Zero:** Quando as caixas (especialmente a mediana) não se sobrepõem, temos forte indício de diferenças estatísticas de médias.



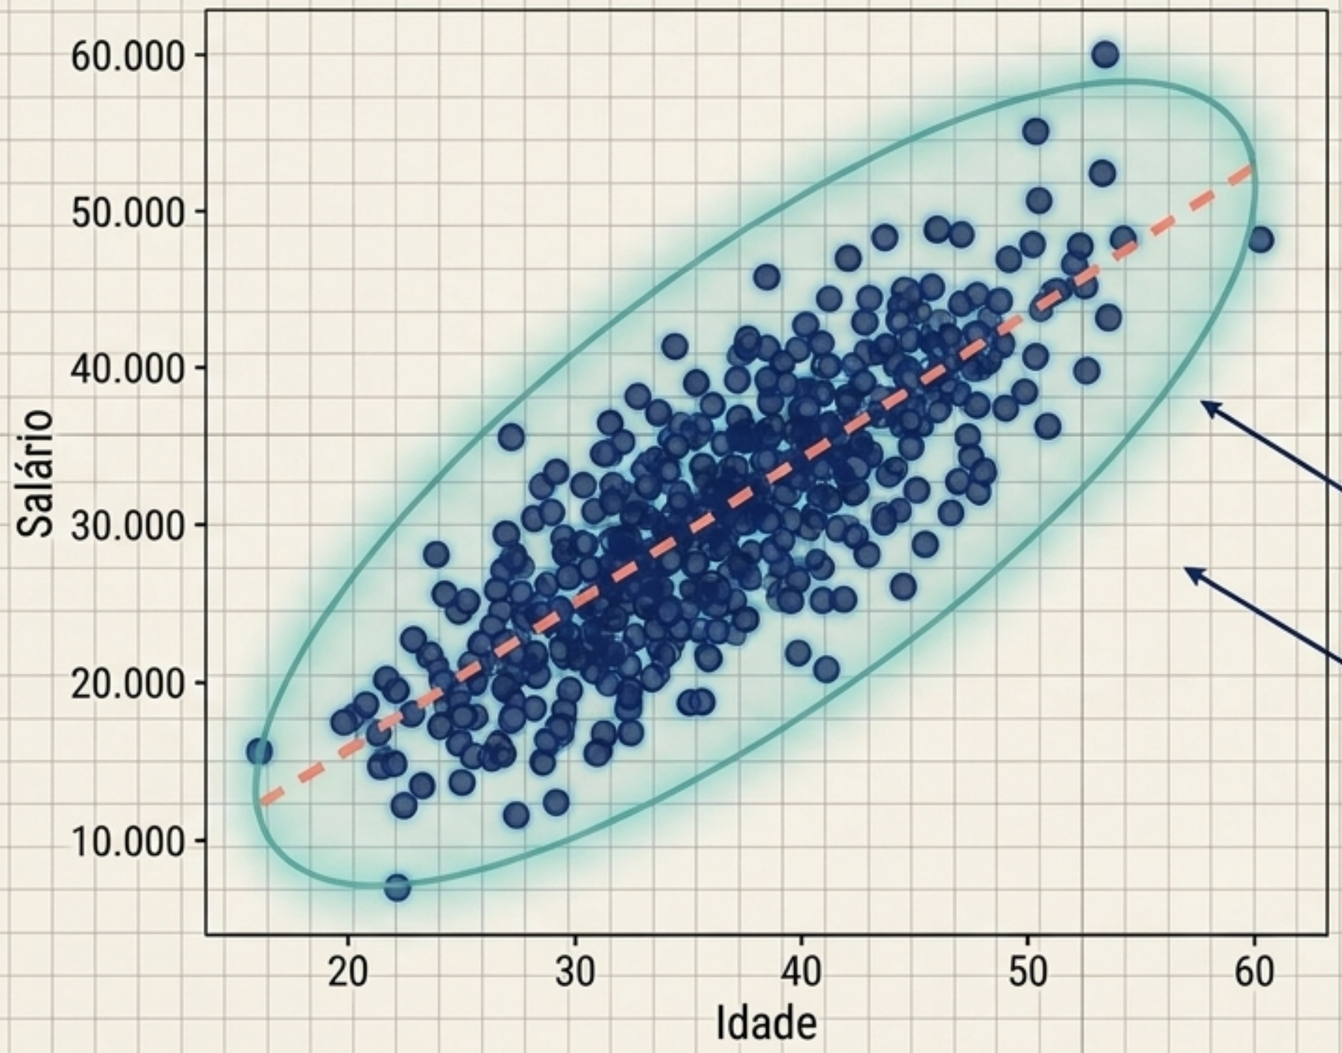
- **Densidade Alisada:** Revela a distribuição real. Picos duplos (bimodalidade) sugerem a presença de um terceiro grupo oculto (ex: diferença de Gênero escondida no agrupamento de Instrução).

O Ganho de Variância (R^2) calcula quanto da variação do salário é explicada exclusivamente pela mudança no grau de instrução.

Gemini Notebook

BLOCO 3: ASSOCIAÇÃO

Quantitativa vs. Qualitativa



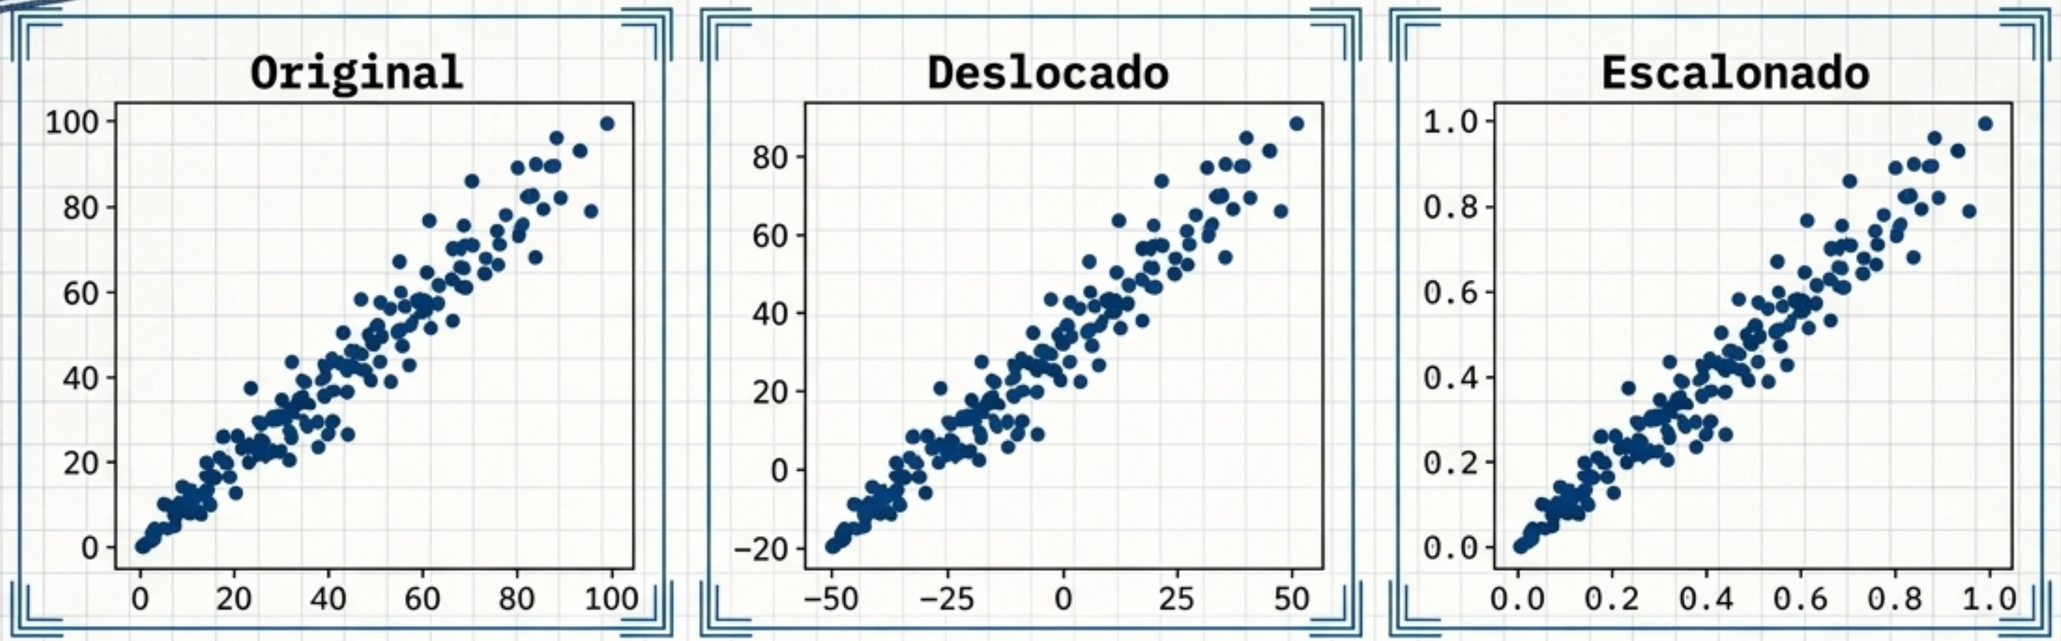
$$r = \frac{Cov(X,Y)}{S_x \cdot S_y}$$

- O **Gráfico de Dispersão** revela se as variáveis "andam juntas" em torno de uma reta.
- O **Coeficiente de Pearson** (r) varia de -1 (correlação negativa perfeita) a +1 (positiva perfeita).
- **Atenção:** Correlação não implica causalidade. O r mede apenas a força da associação linear. Se os dados formarem uma curva (parábola), r pode ser zero mesmo com forte dependência.

Gemini Notebook

BLOCO 3: ASSOCIAÇÃO

A Propriedade de Invariância de Pearson



r = 0.85

Transformações afins não alteram a estrutura da correlação linear.

Seja $u_i = (x_i - a) / b$ e $v_i = (y_i - c) / d$

Se b e d possuem o mesmo sinal ($b \cdot d > 0$):

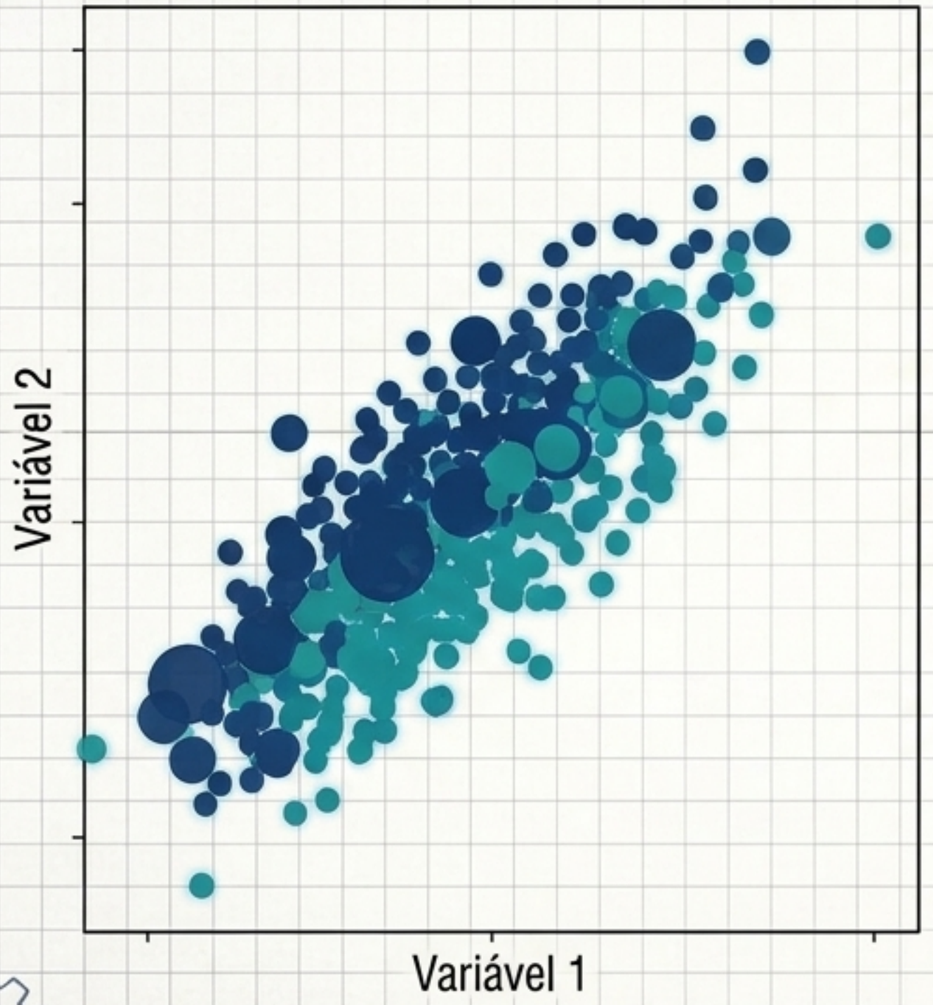
$$r_{uv} = r_{xy}$$

Conclusão: Multiplicar, dividir, somar ou subtrair constantes de suas variáveis (como mudar de Celsius para Fahrenheit) não muda a força visual ou matemática da associação.

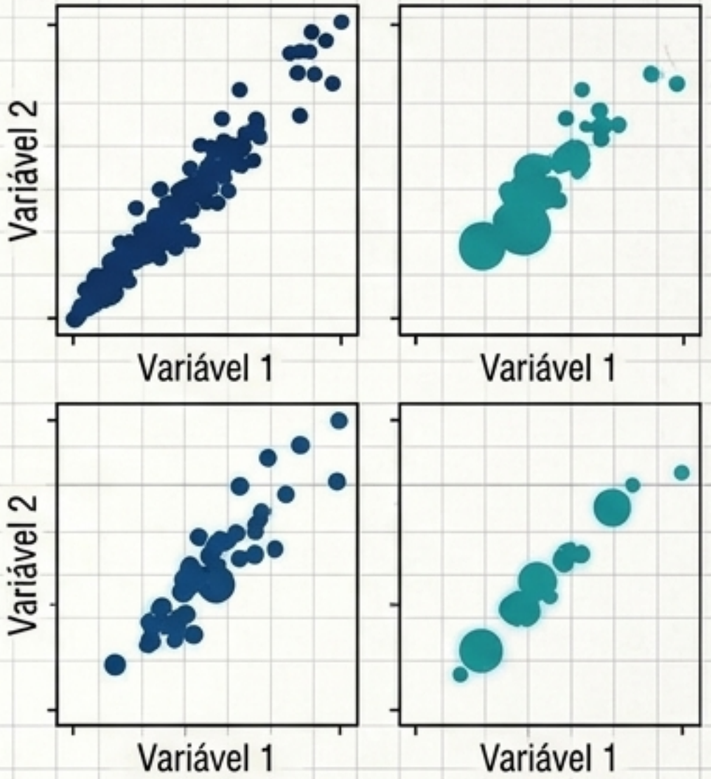
Gemini Notebook

BLOCO 4:
MULTIDIMENSIONAL

Injetando Dimensões no Plano 2D



- **Eixo X e Y**: Posição espacial para dados contínuos.
- **Cor** (Hue): Agrupamento qualitativo (Ex: Gênero, Empresa, Espécie).
- **Tamanho** (Bubble): Uma terceira variável quantitativa (Ex: Saldo em Conta).

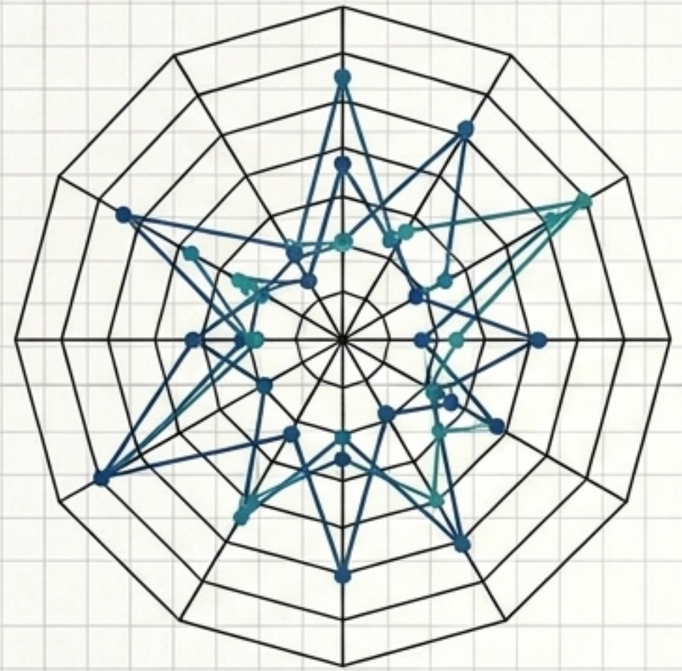


Condicionamento Visual (Trellis/Lattice): Separar os dados em "painéis" baseados em faixas ou categorias para observar se a associação de X e Y muda dependendo de Z.

Gemini Notebook

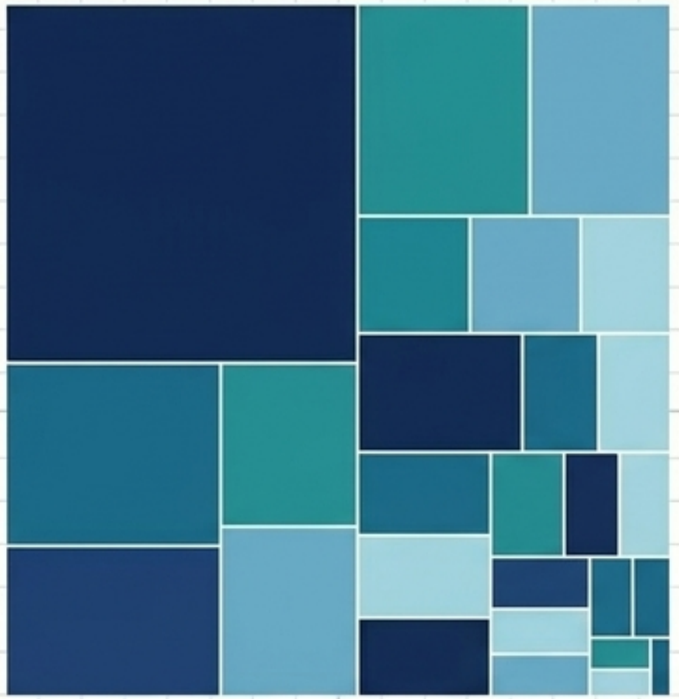
BLOCO 4:
MULTIDIMENSIONAL

Ferramentas Avançadas de Hierarquia e Perfil



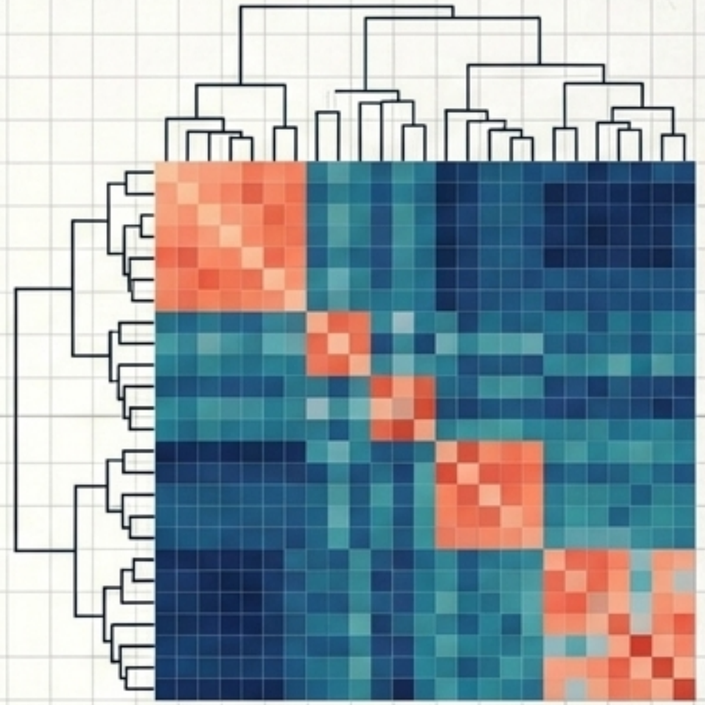
Radar / Estrelas

Ideal para comparar “perfis” individuais em múltiplas métricas padronizadas.



Treemap

Perfeito para estruturas aninhadas.
Área = Grandeza (População);
Cor = Intensidade (Renda).



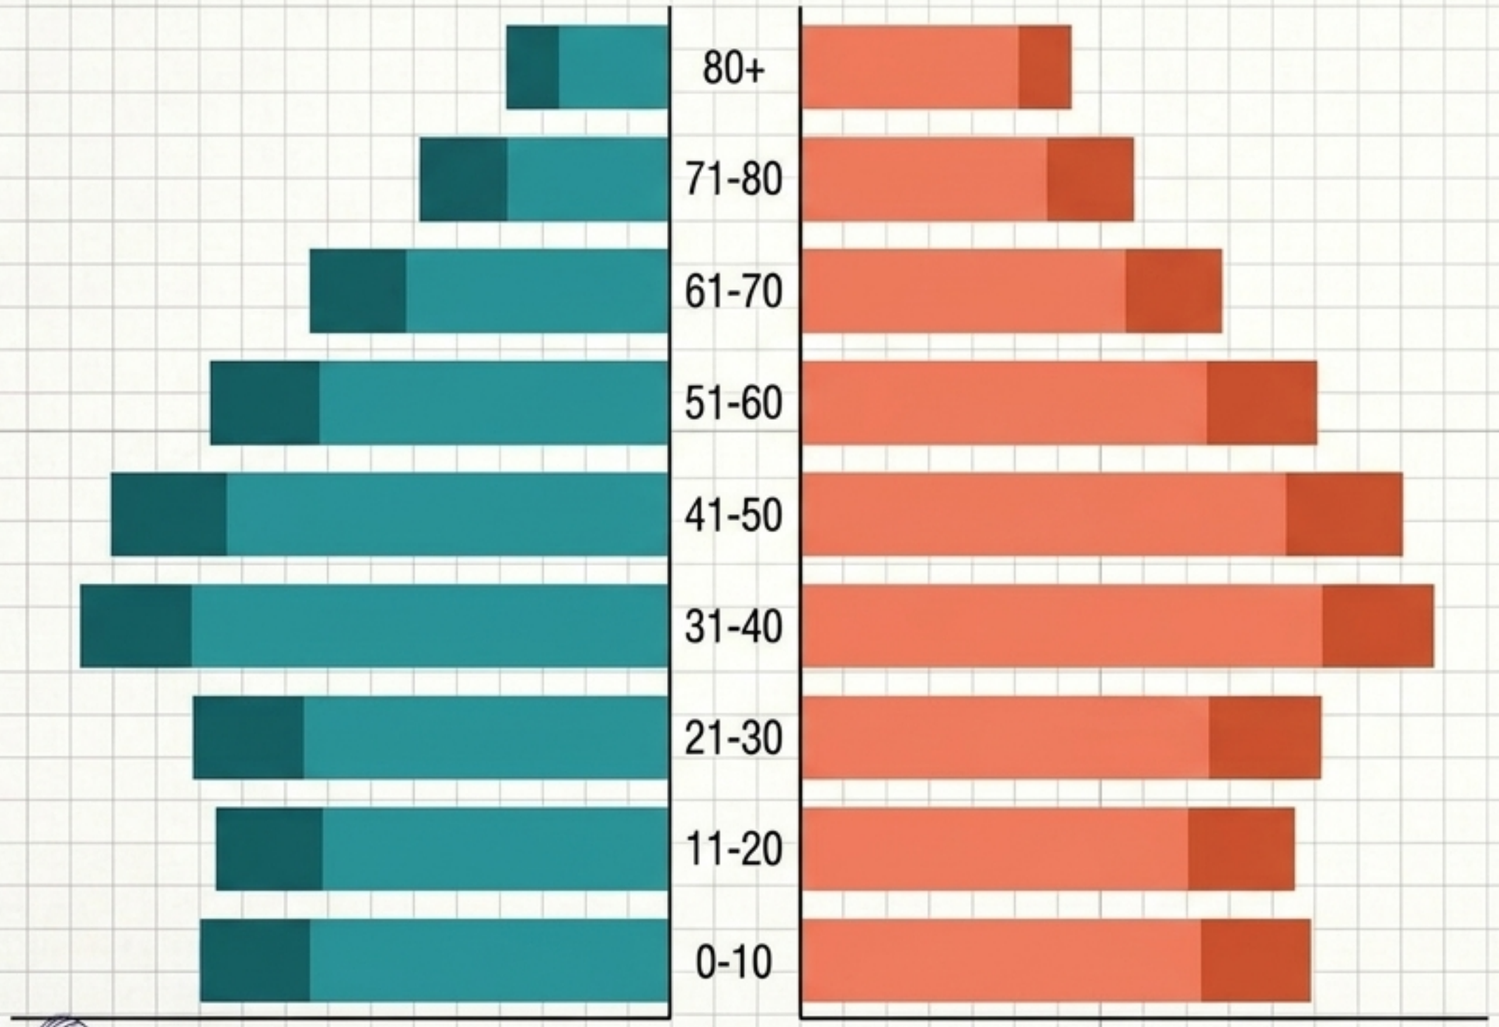
Heatmap + Dendrograma

Crucial para clustering. Agrupa entidades por similaridade de comportamento em um vasto número de variáveis (pixels quentes e frios).

Gemini Notebook

BLOCO 4: MULTIDIMENSIONAL

Perfis Opostos: A Pirâmide Etária



- **O que é:** Uma composição de dois gráficos de barras opostos, divididos por uma variável qualitativa binária (geralmente Sexo).

- **O poder da proporção:** Permite observar não apenas a demografia bruta, mas a proporção de um fenômeno (ex: incidência de COVID-19) dentro de faixas específicas da população em tempo real.

- **Mudança temporal:** Acompanhar o alargamento ou achatamento das barras revela as mudanças estruturais de uma sociedade ao longo dos anos.

Gemini Notebook

BLOCO 4: MULTIDIMENSIONAL

A Árvore de Decisão da Visualização

O Algoritmo da Exploração

Tenho Dados

- **1 Variável**
  - **Quantitativa** → Histograma / Boxplot
  - **Qualitativa** → Gráfico de Barras
- **2+ Variáveis** → Qual o objetivo?
  - **A** Relação Qual x Qual → Mosaico, χ^2
  - **B** Relação Quant x Qual → Boxplot / Violino condicionado
  - **C** Relação Quant x Quant → Dispersão, Correlação (r)
  - **D** Agrupamento Complexo → Heatmap, Treemap

O design de informação não é apenas sobre estética. É sobre escolher a lente matemática correta para expor os segredos ocultos na estrutura dos dados.

Gemini Notebook